

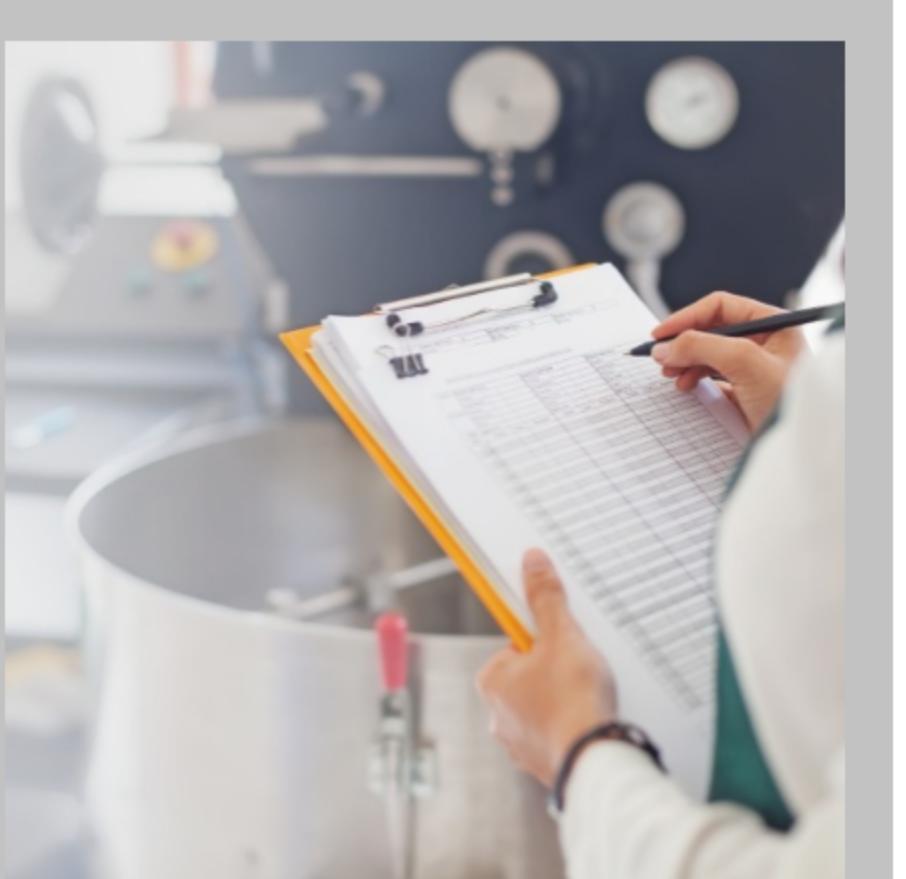
# UP' TOWN



AI를 이용한 연삭 훈수명 관리 및 교체시기 예측 솔루션

# UpTown

업타운은 빅데이터 솔루션 유통 및 개발의 선두주자로서  
다수의 운영 및 보안 관제 구축을 통해 특화된 노하우를 보유한  
빅데이터 기반 인공지능 서비스 전문 기업입니다.



## 고객 맞춤형

빅데이터 분석 및 보안 분야에서  
고객의 환경에 맞는  
서비스를 제공하며  
다양한 구축 경험을 가지고 있습니다.



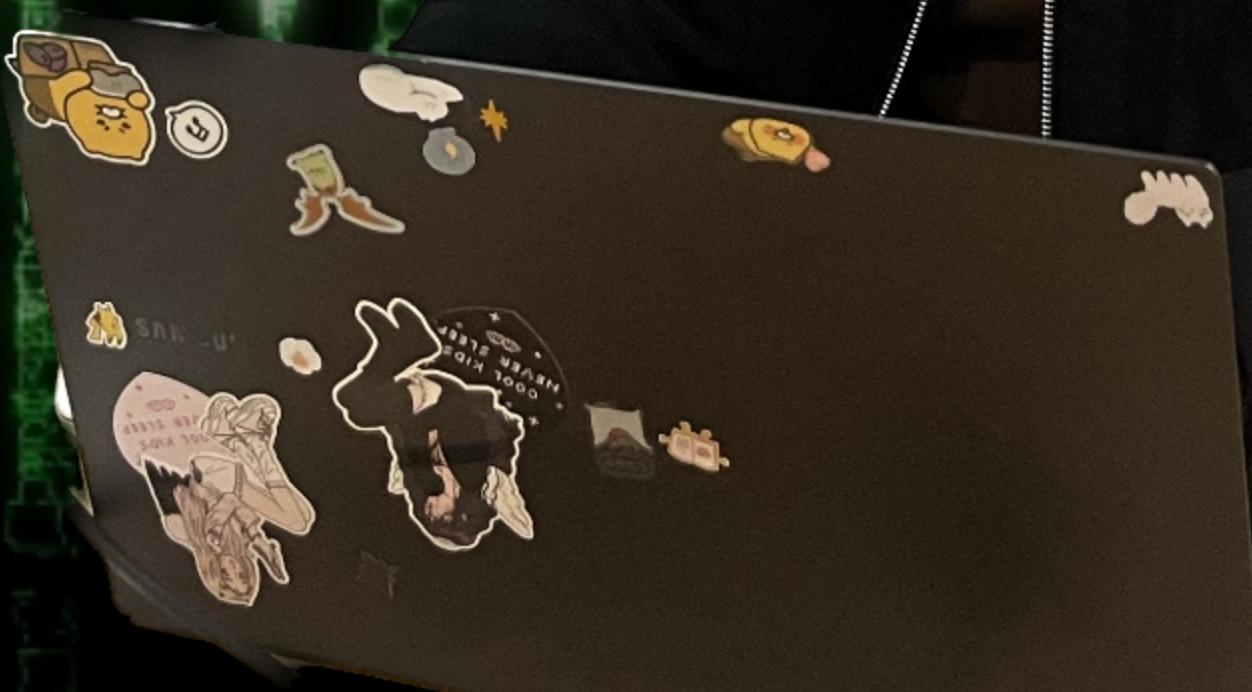
## 자체 개발 플랫폼

자체 개발한 빅데이터 인프라와 인공지능 분석  
플랫폼을 기반으로한  
데이터분석정보 서비스를 통해 고객사에 맞는  
빅데이터 가치를 제공합니다.





## Lv.25 냉철한 개발자



### KEYWORDS

- 논리
- 냉정
- 순발력

### CONTACT

인스타그램 @CHOI\_GGUE  
이메일 KIMKY944@GMAIL.COM  
휴대폰 82+10 3318 7966

### SKILLS

- 코딩 ★★★★
- 논리력 ★★★★
- 두뇌회전 ★★★★
- 스킬 ★★★



# 강보원

Lv.26 똑순이 개발자

강보원, 어떻게 연락해?

e-mail : iambowonkang@gmail.com  
번호 : 010 4024 6255



강보원, 잘하는 건?

PYTHON

R-STUDIO

SQL

JAVA

C언어



## KEYWORDS



웹 개발자 최정인



최정인 / 개발자 / 26세

junginmay17@naver.com

# 기획자 박현명

Lv.29 전략형 기획자



## KEYWORDS

감각

기획

판단력

## SKILLS

기획

마케팅

데이터분석

디자인

## CONTACT

인스타그램 @WISDOMHAPPY

이메일 WISDOM01636@NAVER.COM

휴대폰 82+10 9289 8184

# CONTENTS

프로젝트 개요 01

데이터 설명 02

홈페이지 설명 03

프로젝트 세부내용 보고 04

기대효과 05

프로젝트 소감 06



01

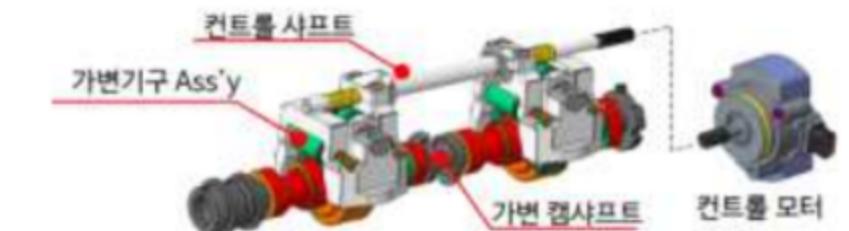
프로젝트 개요

# 의뢰기업 : 서진캠

자동차 부품 생산 업체로 단순한 공정 개선이나 품질 향상을 넘어  
신기술, 신공법, 신제품 연구개발에 많은 투자와 회사의 역량을 집중하고 있으며,  
이를 토대로 시장을 선도하는 혁신제품개발과 최고수준의 품질 확보 실현중인 기업  
<주요고객> 현대자동차, 기아, 현대글로비스, 현대위아, GM KOREA, 현대모비스, 쌍용자동차

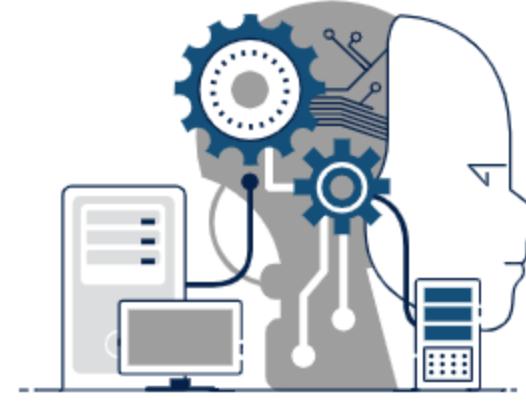


<생산 품목>



엔진형	구분	비고
V6	3기통	
V8	4기통	
V10	5기통	

## 의뢰 기업이 겪고 있던 상황



기본적인  
스마트 공장  
구축 준비 완료



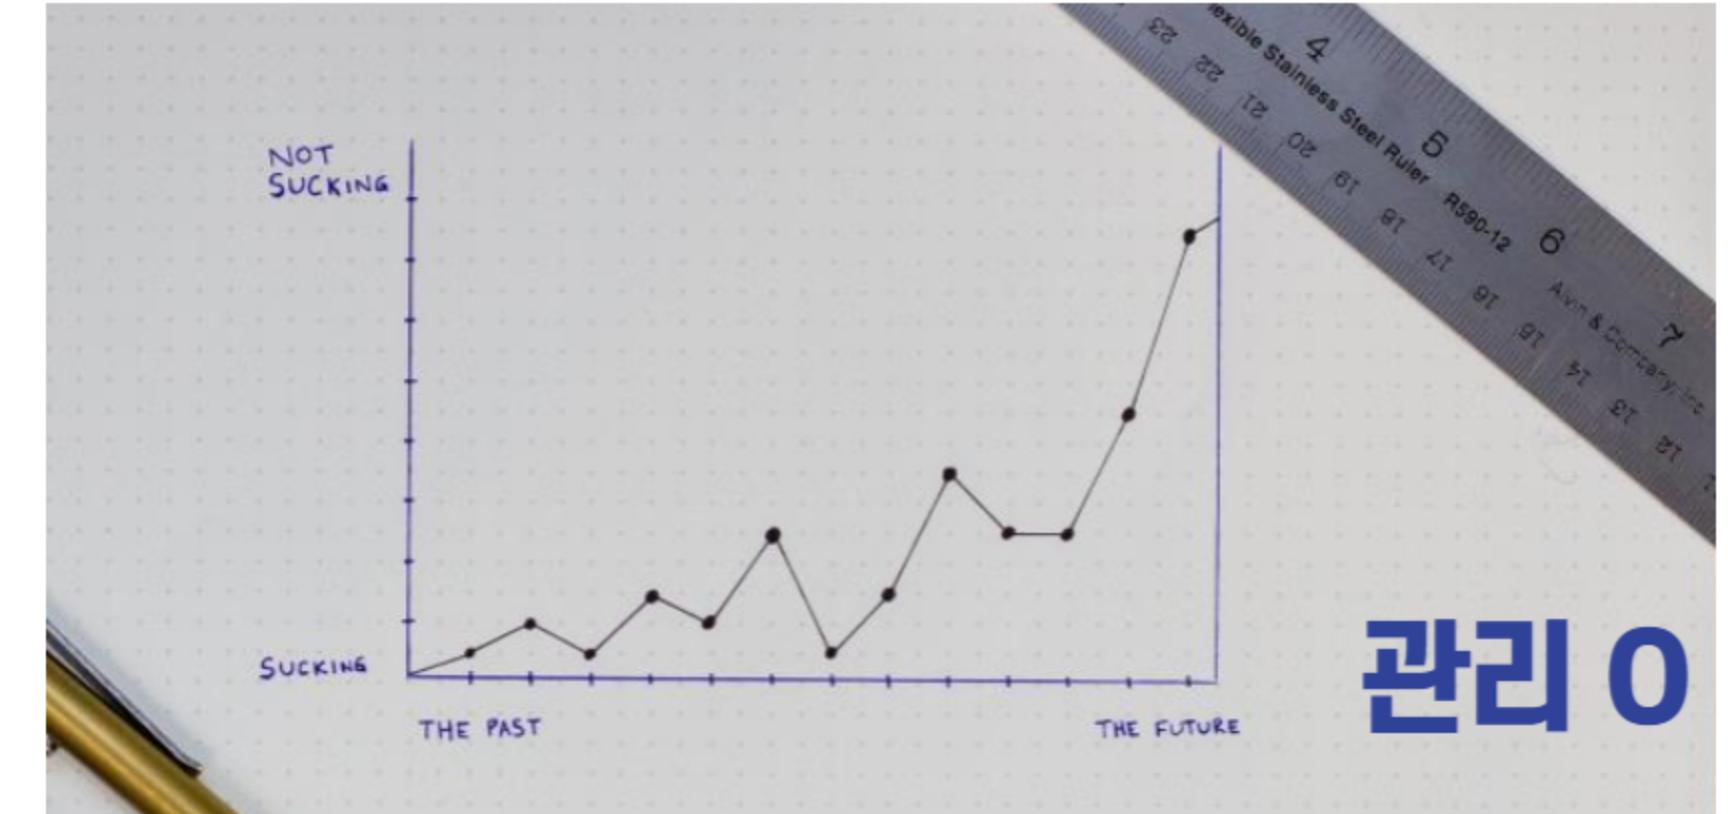
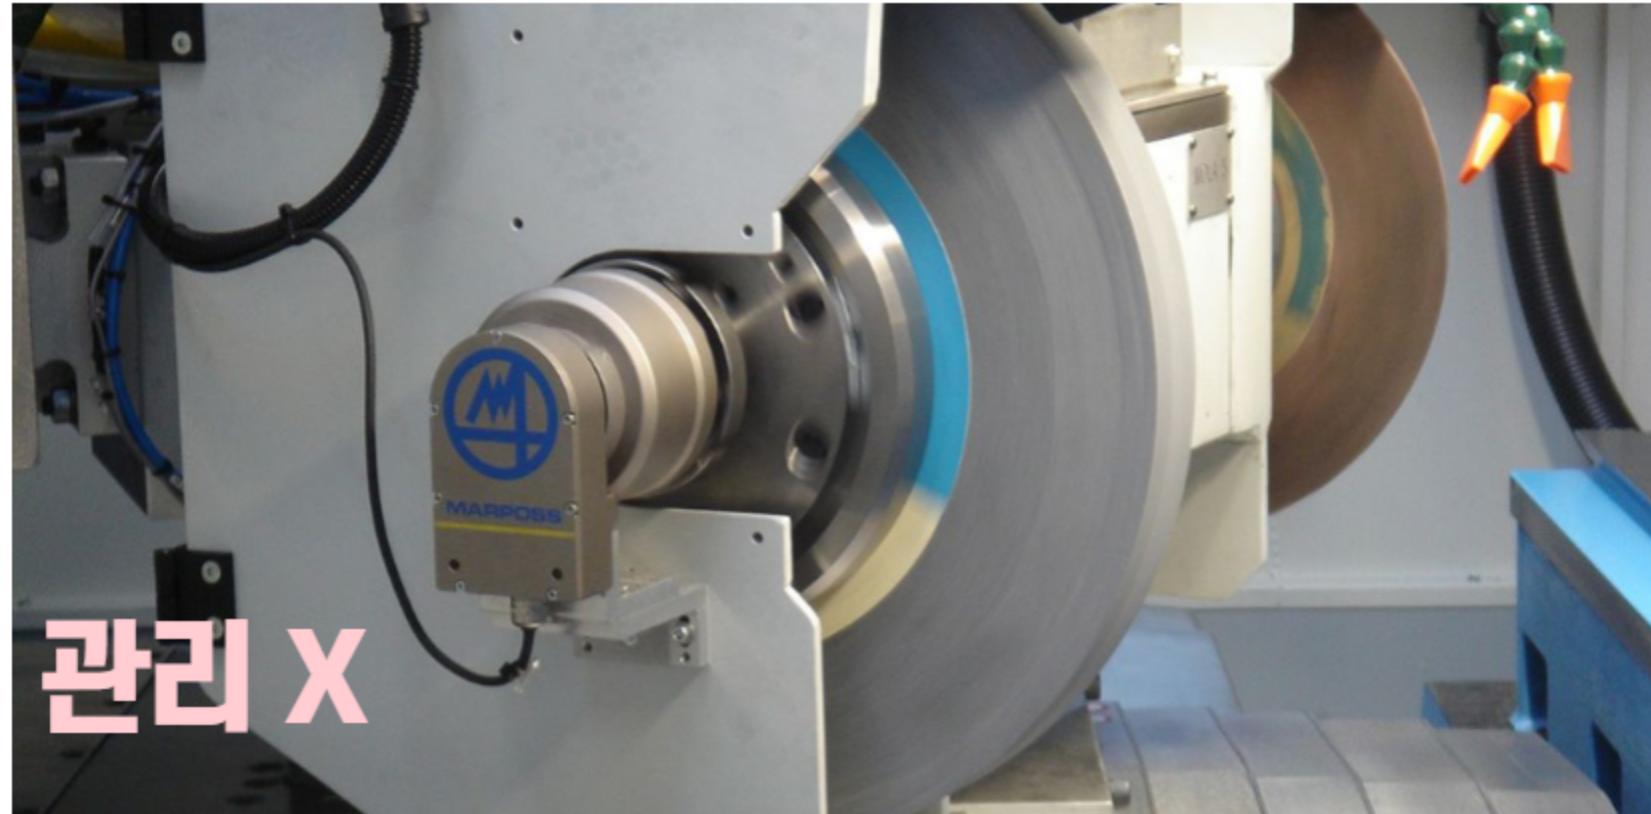
수집되는  
빅데이터  
활용 X



품질 향상에  
대한 요구사항  
증가

“설비에서 발생하는 데이터를 AI와 융합하여,  
설비의 건전성을 파악하고자 함”

# 정기적인 연삭휠 드레싱과 컨디셔닝 작업의 필요성



① 불필요한 관리 지출(고비용)

② 장비 스팬들 같은

중요 부품에 필요 이상의 스트레스

① 연삭 벼닝 현상 감소

② 연삭휠의 생산성과 효율성 극대화

③ 연삭 품질 향상



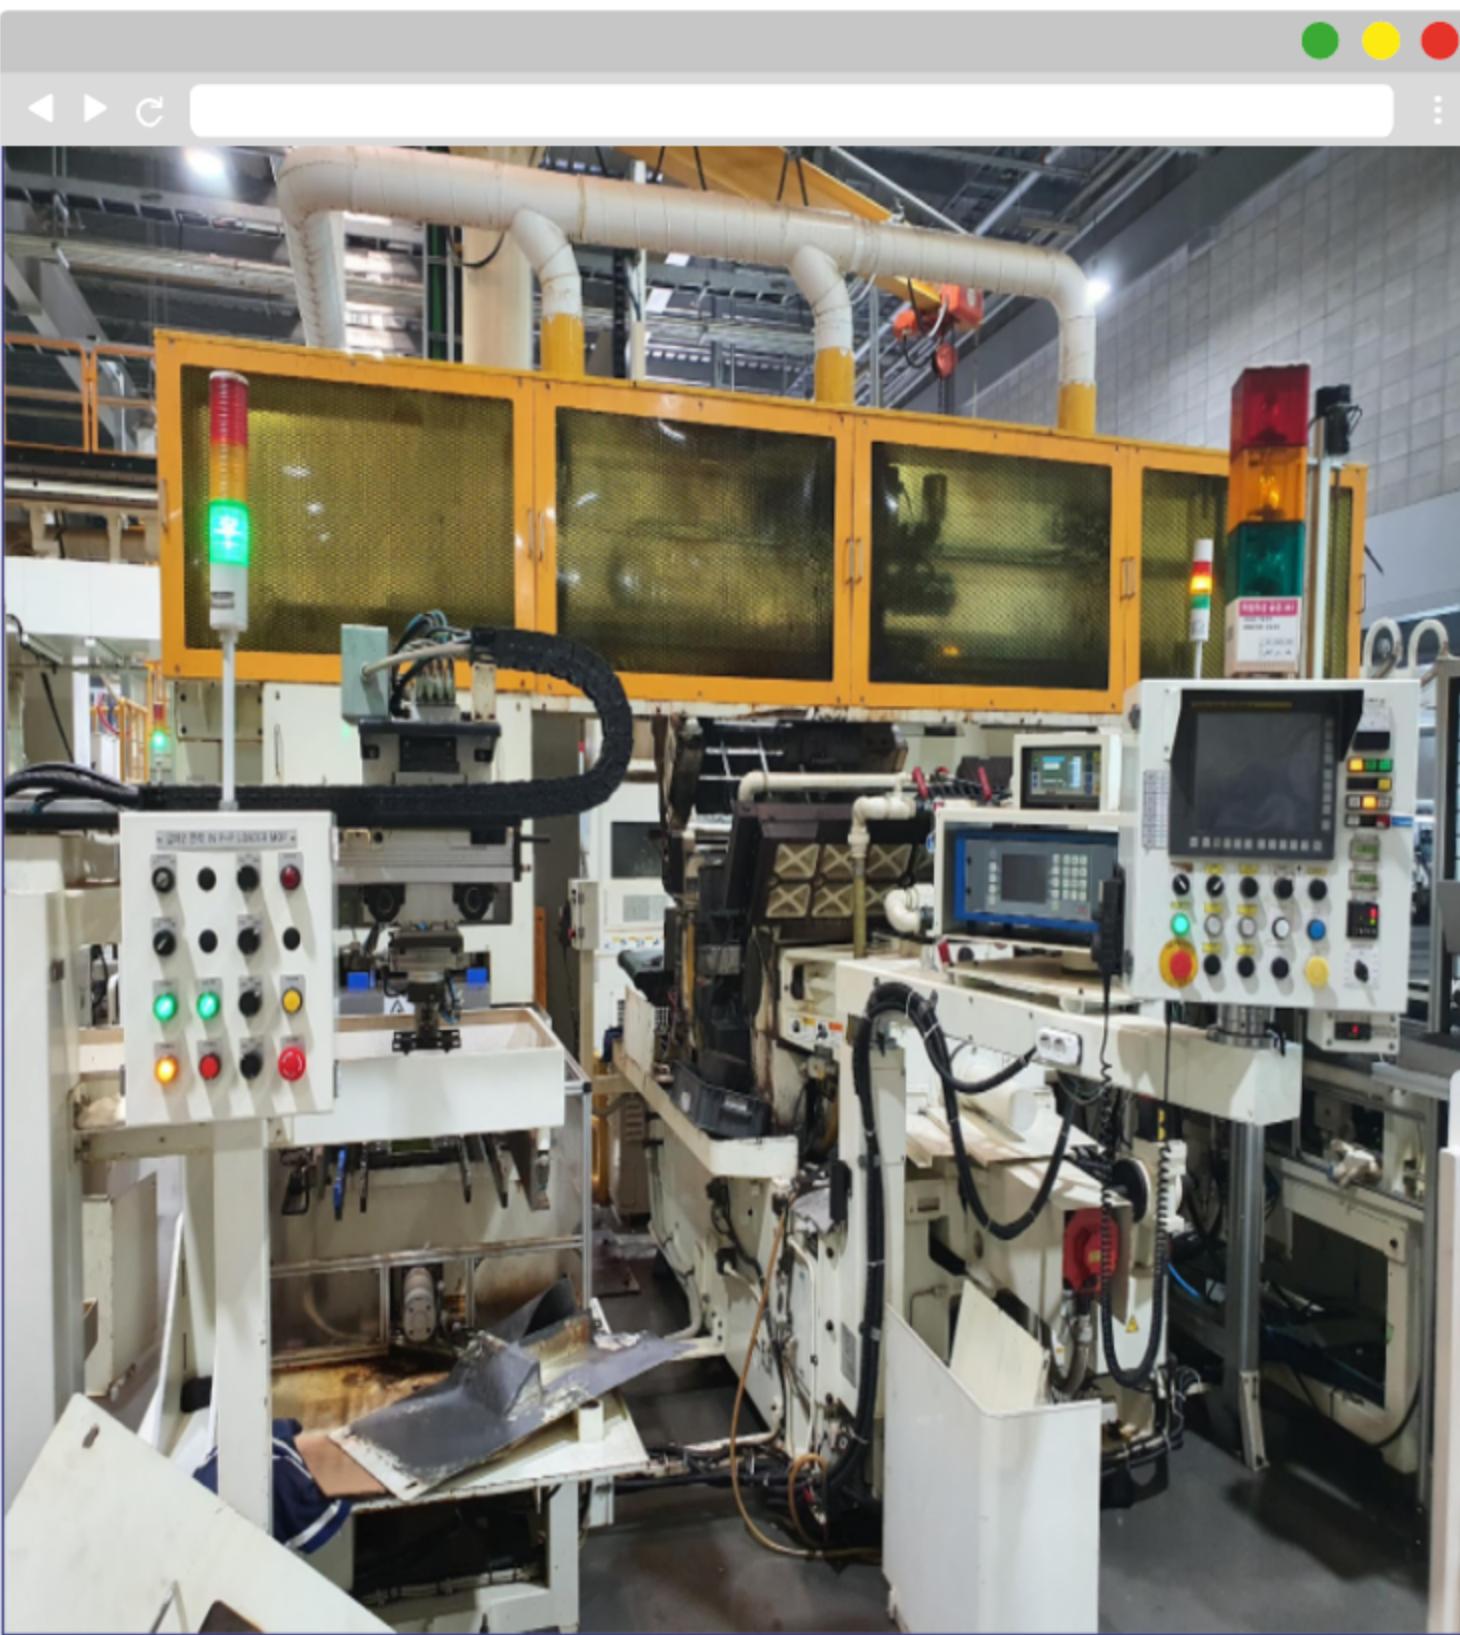
연삭기 센서 데이터 및 MES 분석을 통한  
연삭 훈수명 관리 및 교체 시기 예측 솔루션



## 02

# 데이터 설명

# 데이터 수집 대상 장비



▶ 센서가 부착 될 연삭기 장비



▶ 센서 데이터가 수집 되는 Edge PC

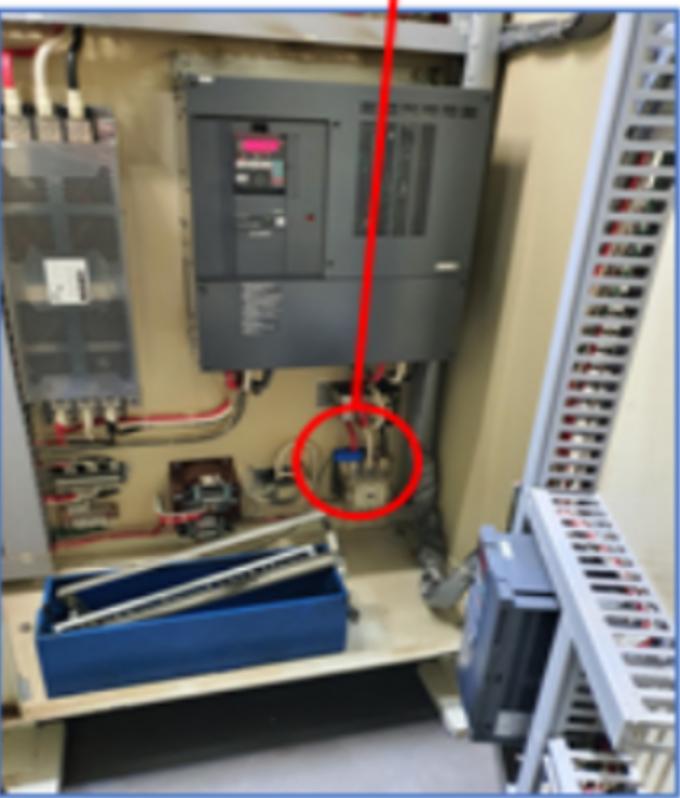
# 센서 데이터 수집 구성도

A/D Converter  
센서 신호 변환 장치

Edge Computing  
센서 데이터 저장 및 필터링

전류센서

진동센서



Database  
데이터 저장



# 수집 데이터 리스트

## Edge PC 수집 데이터



- ▶ 전류 센서 1개
- ▶ 진동 센서 1개
- ▶ EdgePC 상태

## 연삭휠 데이터

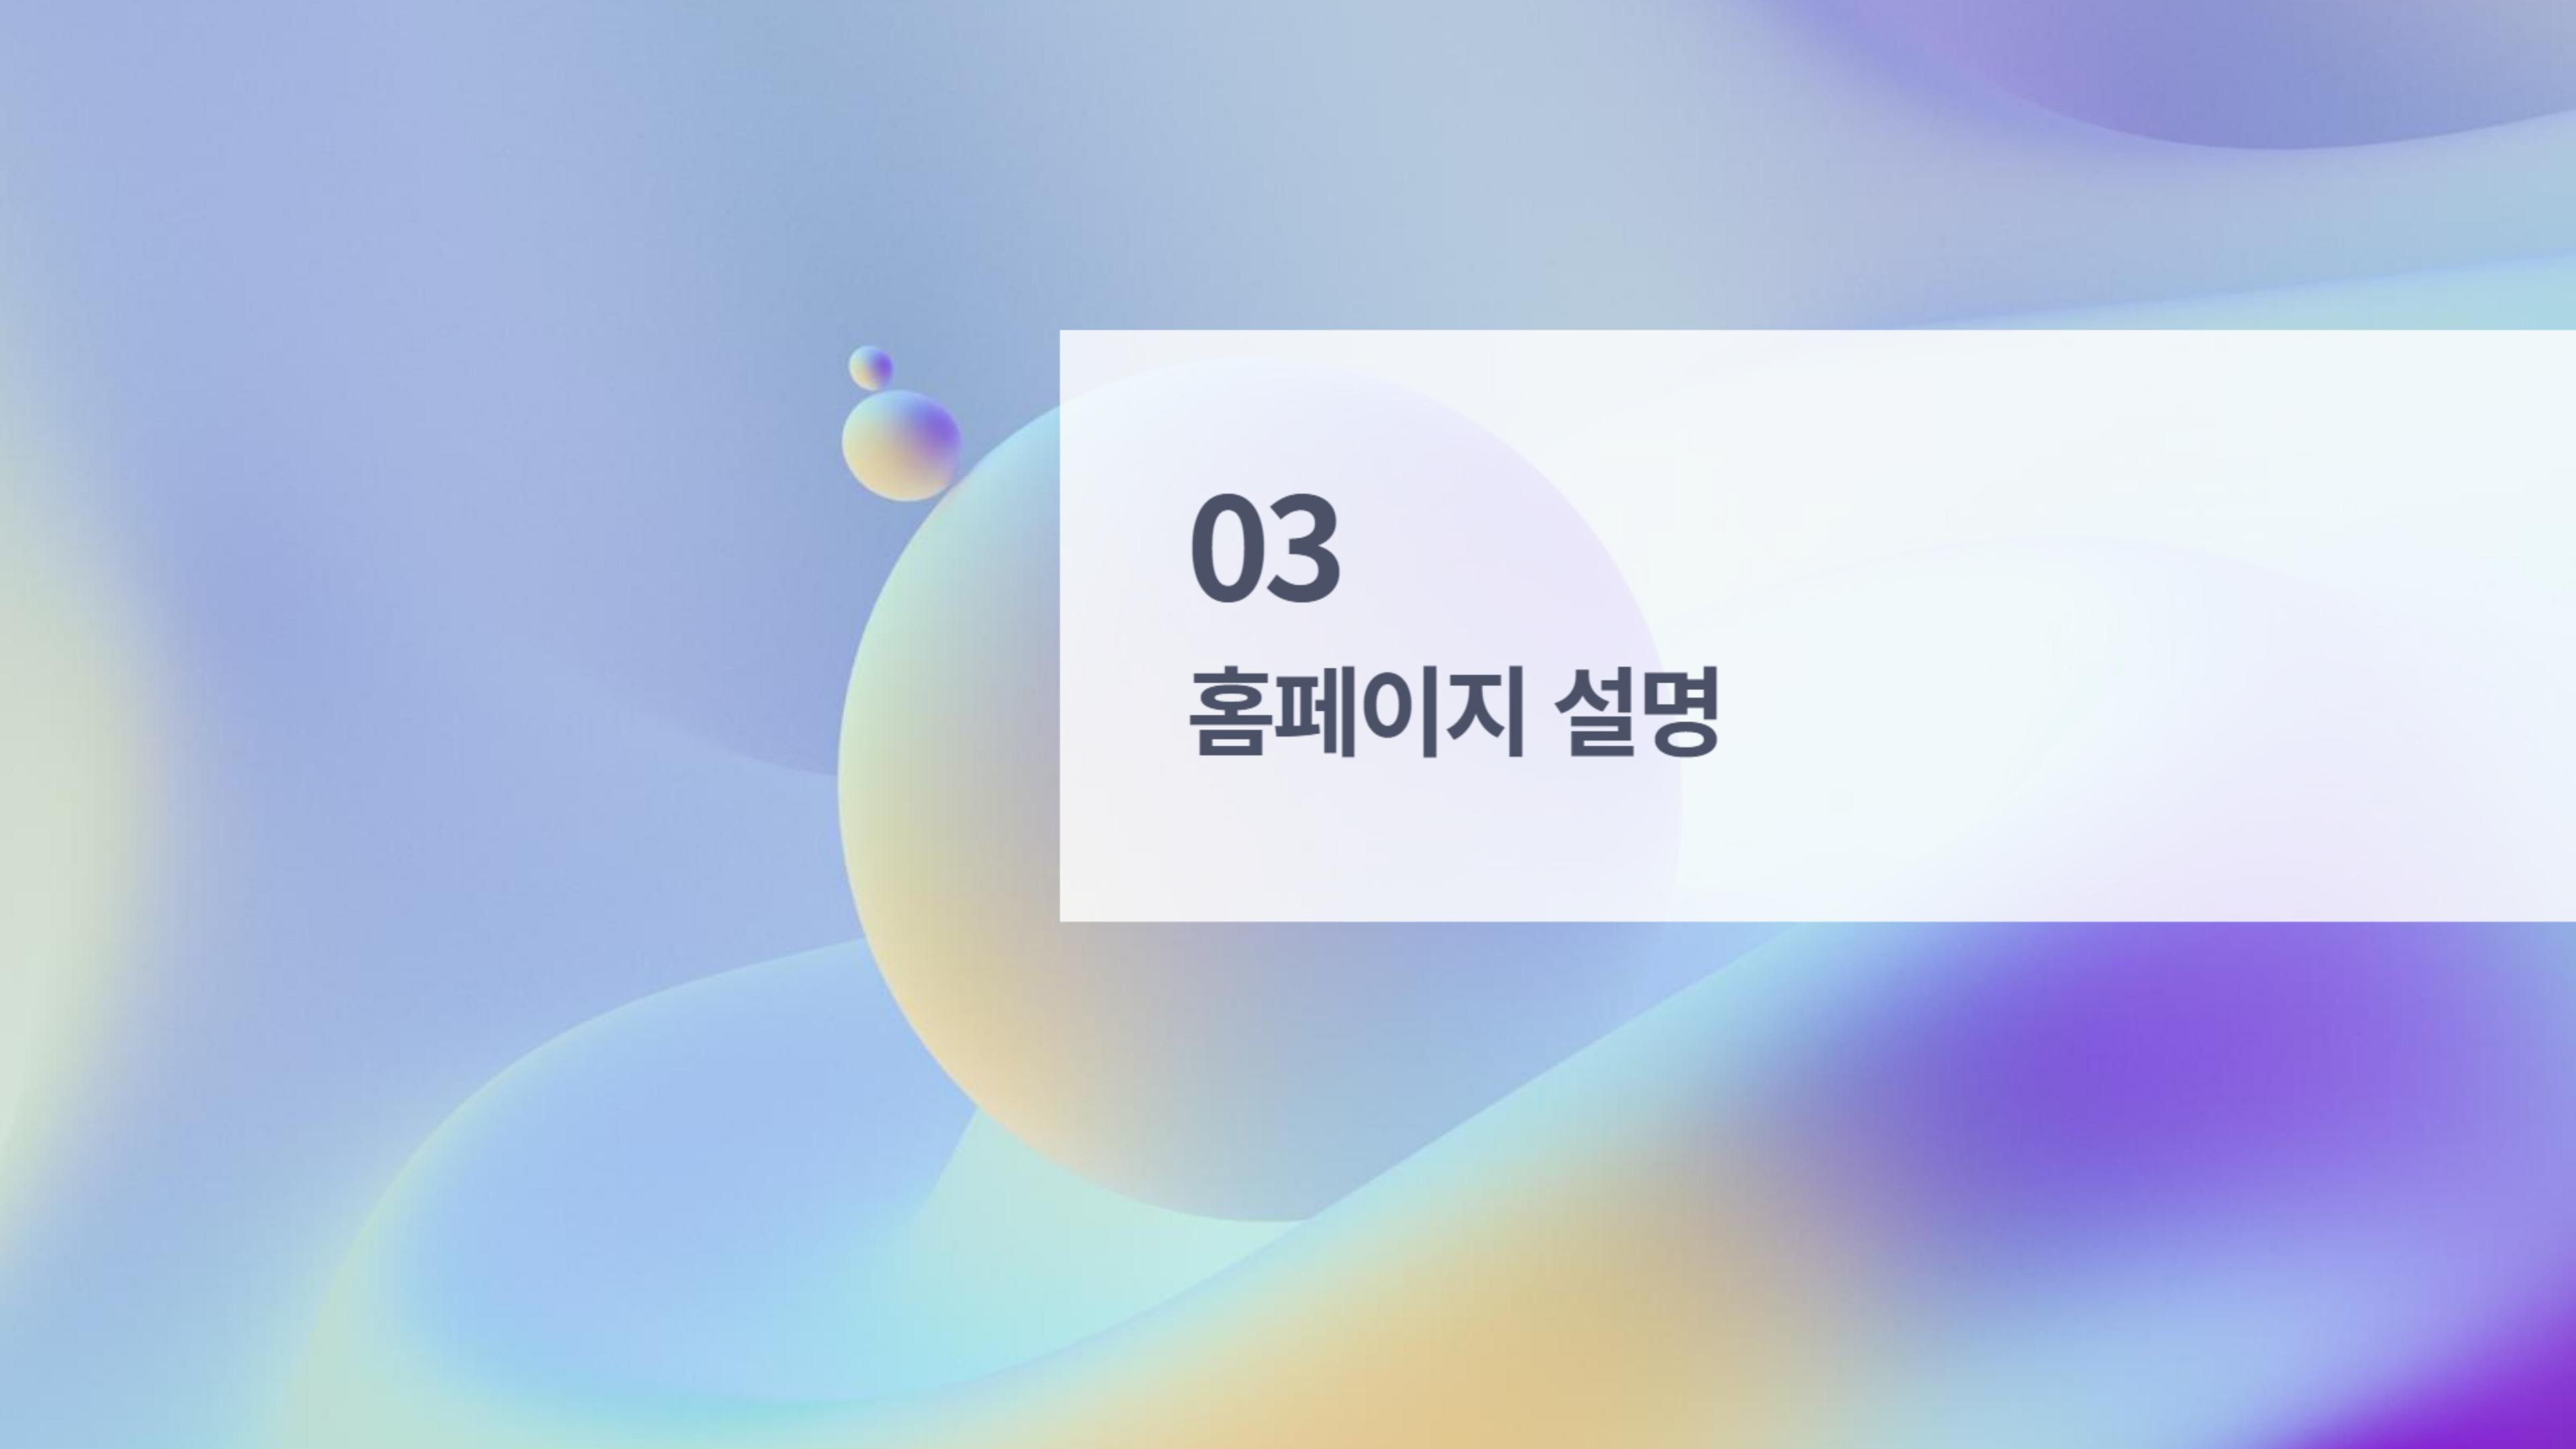


- ▶ 훨 잔량
- ▶ 드레싱 주기
- ▶ 동작 상태

## MES 데이터



- ▶ 생산 실적
- ▶ 재고 현황
- ▶ 불량 판정



# 03

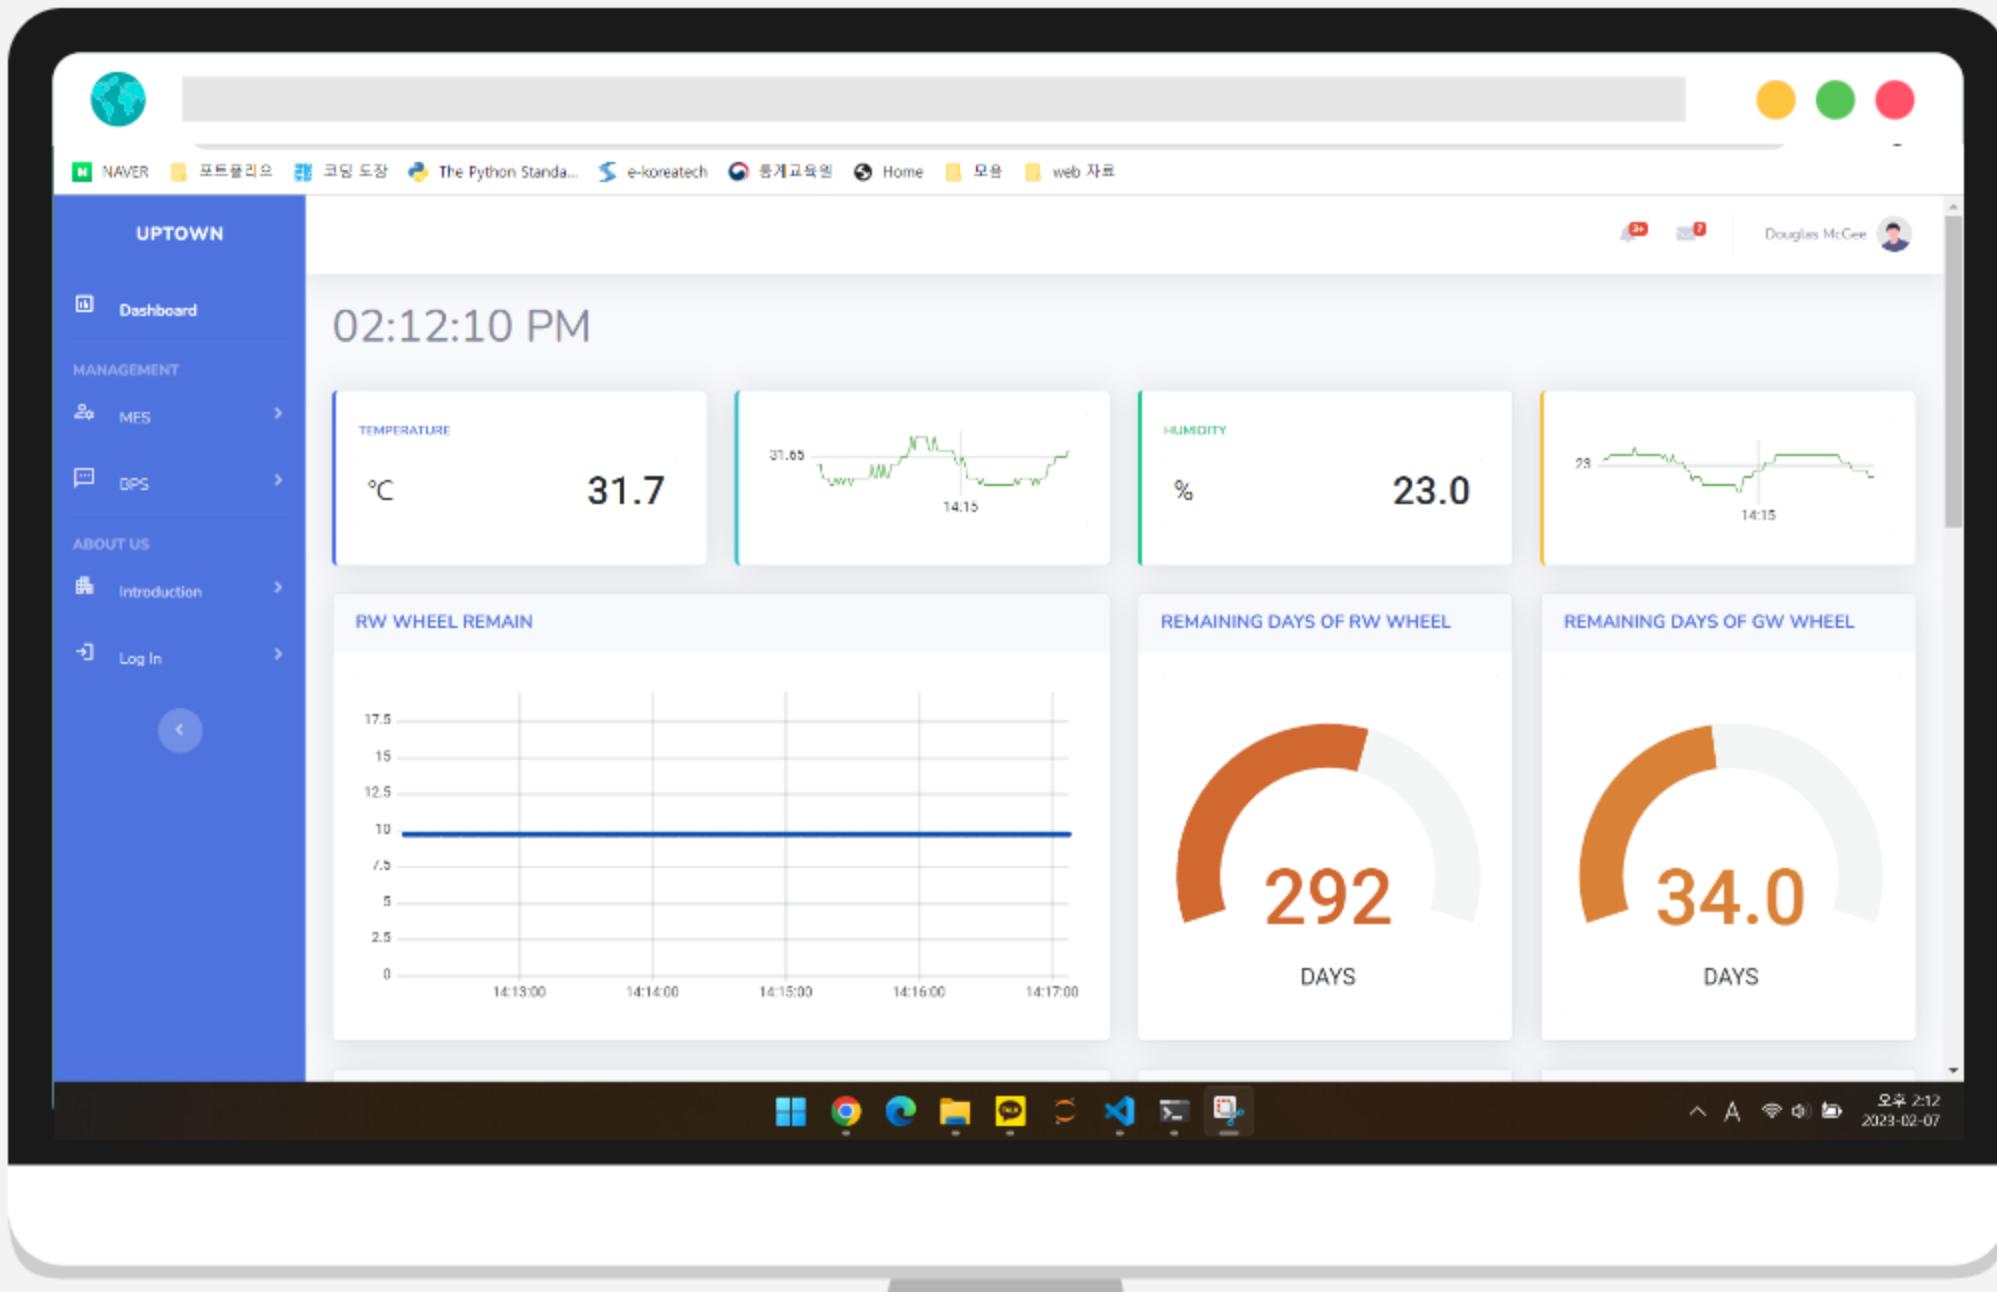
## 홈페이지 설명

# 제작 홈페이지 상세설명

: UI 및 기능 설명

## 01. Dashboard

- 전반적인 설비 기능 시각화
- 온도/습도 시스템 상태 ,  
RW 훈장량 상태,  
RW/GW 훈장량 예측 잔량에  
따른 교체 시기 예측 표시



## 02. MES

- MES 페이지로서,  
생산현황, 재고 개수,  
불량품 개수 관련 데이터 표 표시

## 03. BPS

- 누적 출입고량, 불량품 개수,  
기업의 비전과 미션, 장기 목표 리스트,  
부서별 요구 사항 입력 폼

## 04. Introduction

- 기업 소개, 팀원 소개,  
찾아오는 길, 문의 사항

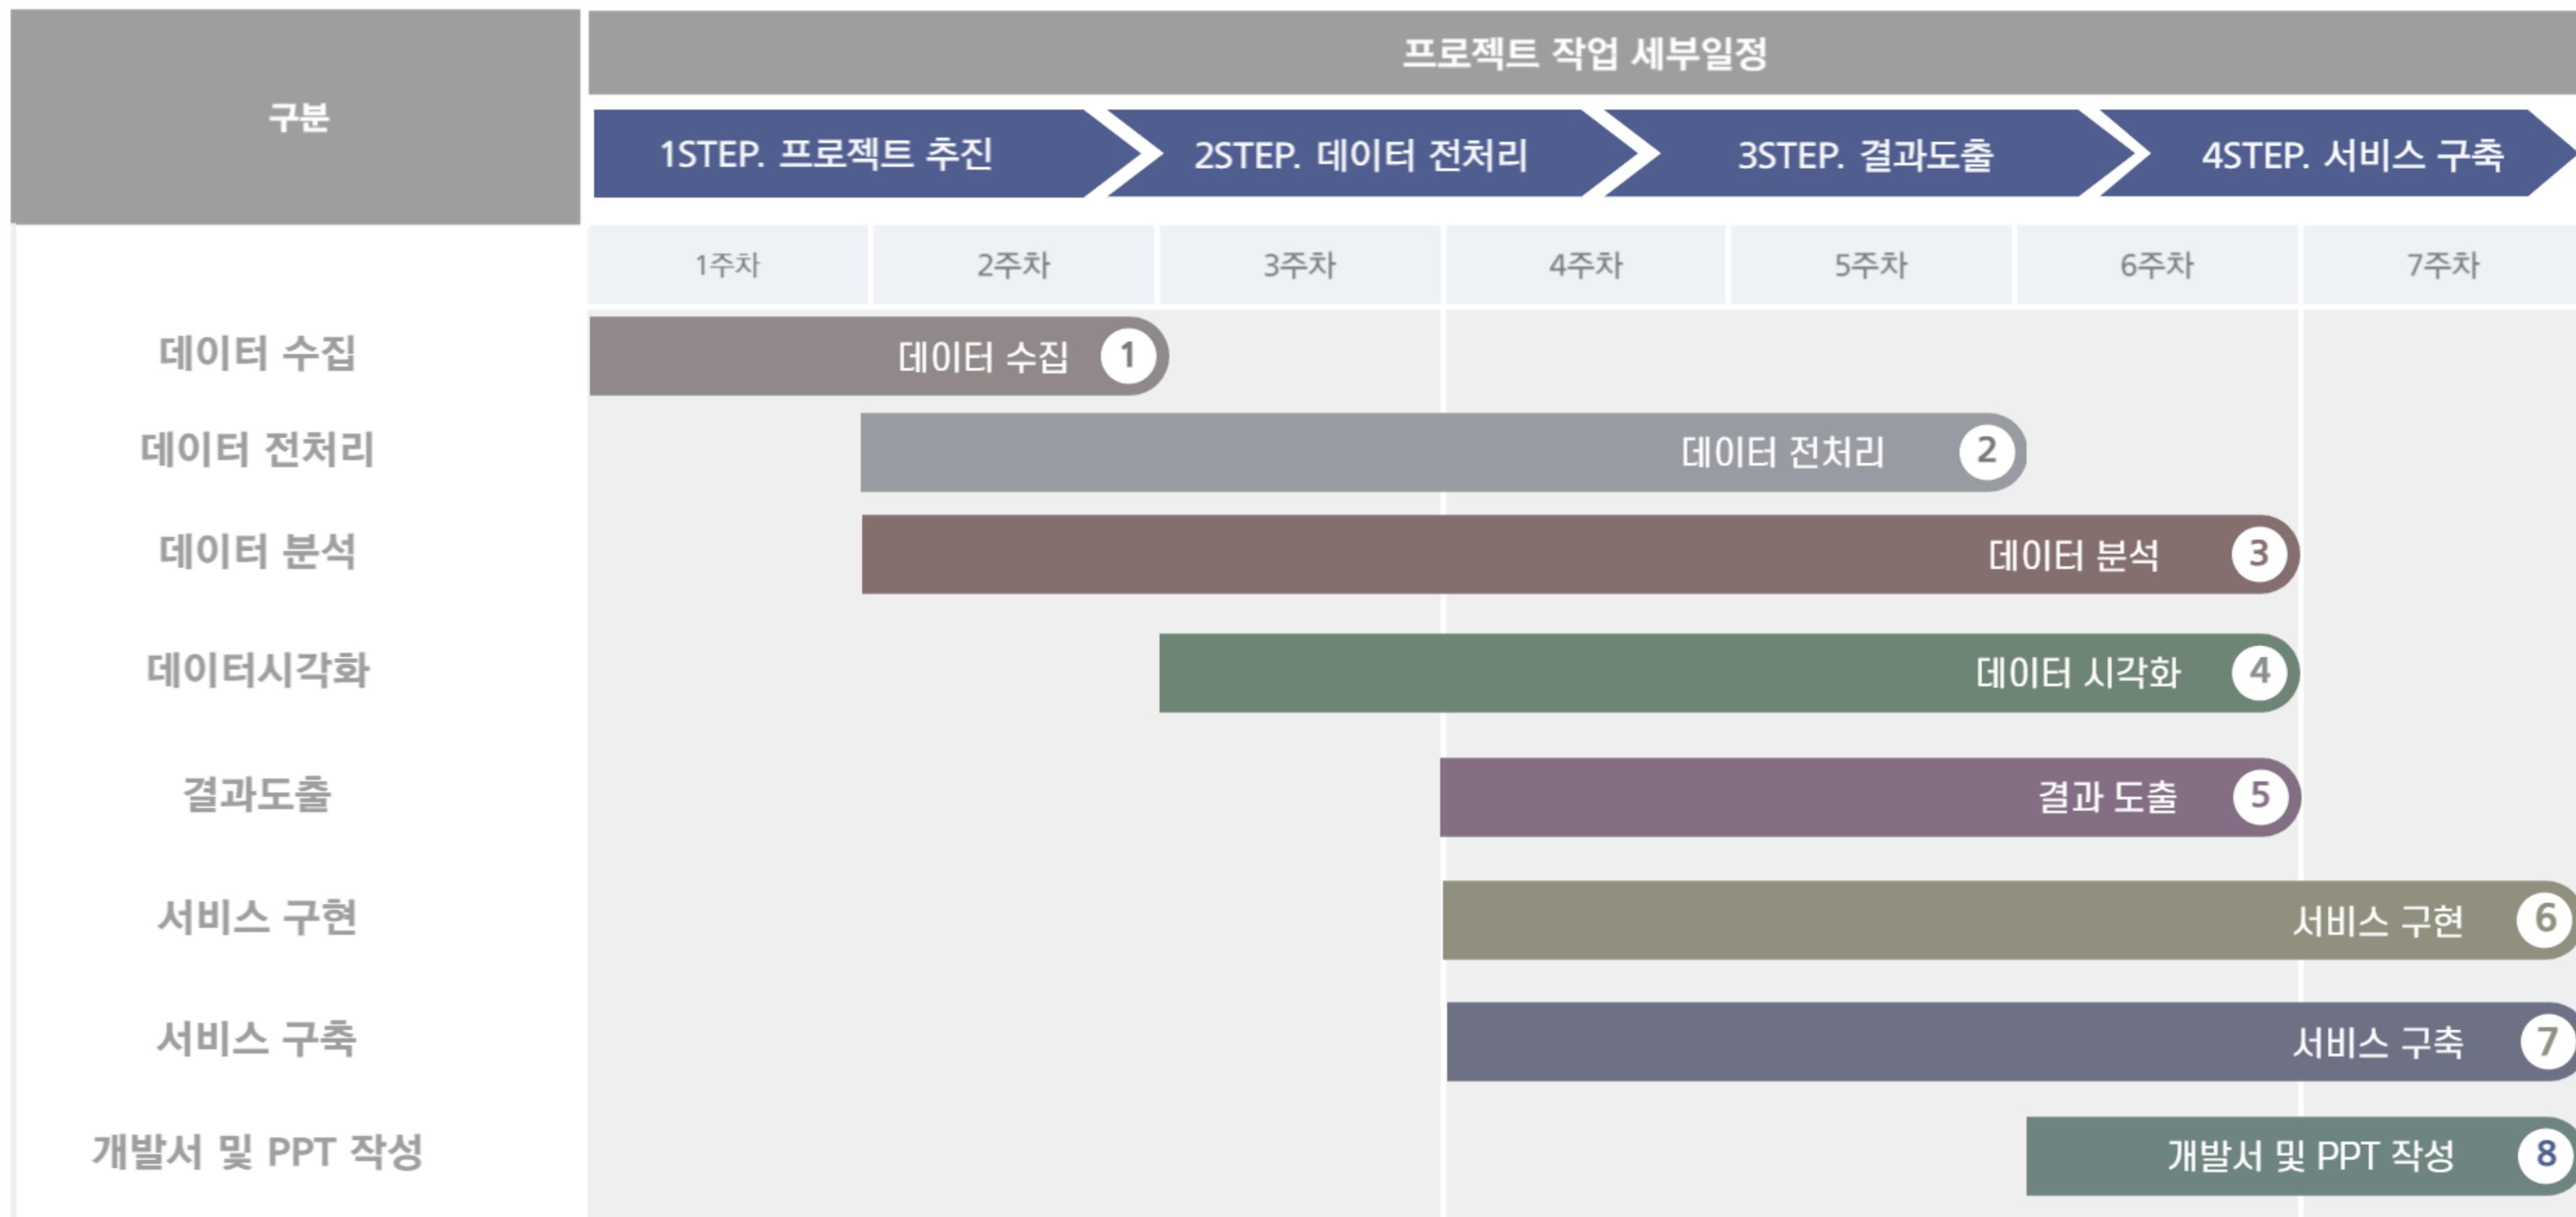
## 05. Log in

- 로그인, 회원가입, 마이페이지 창

04

## 프로젝트 세부내용 보고

# 프로젝트 스케줄



# 개발환경

01

OS (운영체제) 버전

Windows 10

Windows 11

02

개발툴

Colab pro+

03

데이터 베이스

influxdb 1.8.10

04

형상 관리

Git, GitHub

05

데이터 분석 버전

Python 3.9.7

- ▷ 전처리 : Numpy 1.23.0, Pandas 1.4.3, FFT, PCA, t-SNE 알고리즘
- ▷ 시각화 : Grafana 9.3.2
- ▷ 머신러닝 : Keras 2.9.0, Tensorflow 2.9.2, Scikit-Learn 1.0.2
- ▷ 딥러닝 : ARIMA, LSTM

06

웹 개발 프레임워크

Django 4.1.5

- ▷ 프론트엔드 : HTML5, JS, CSS

# 무엇을 어떻게 예측해야하나?

무엇을?

AI 알고리즘을 사용하여  
훨 잔량을 예측해보자!

어떻게?

7일을 기준으로  
모델을 학습시키고  
다음 1일을 예측!

무엇을?

잔량을 실시간으로 탐지 후  
교체시기를 예측해보자!

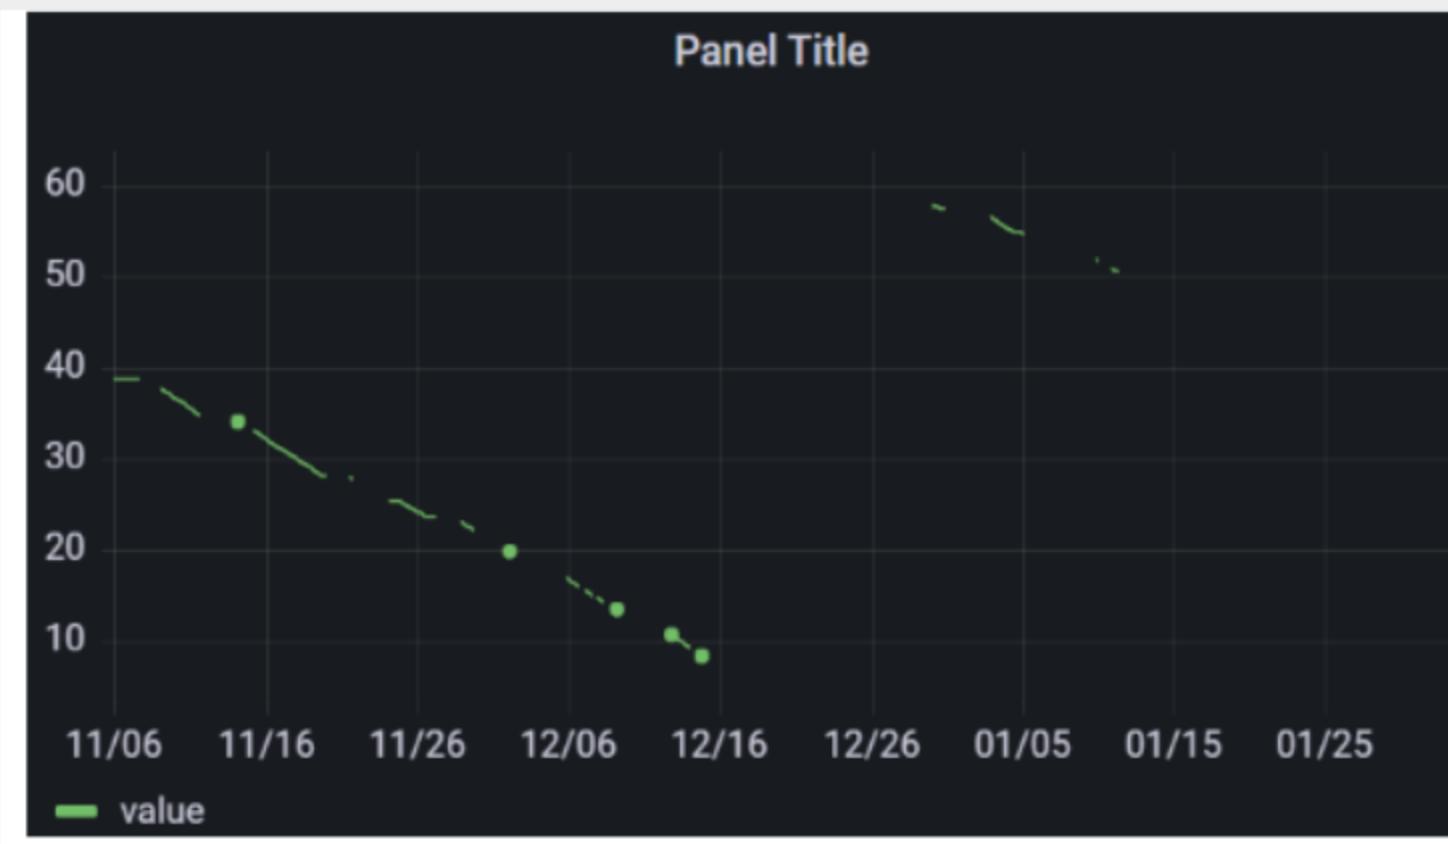
어떻게?

7일을 기준으로  
훨 감소량을 계산하고  
교체 시기 예측!

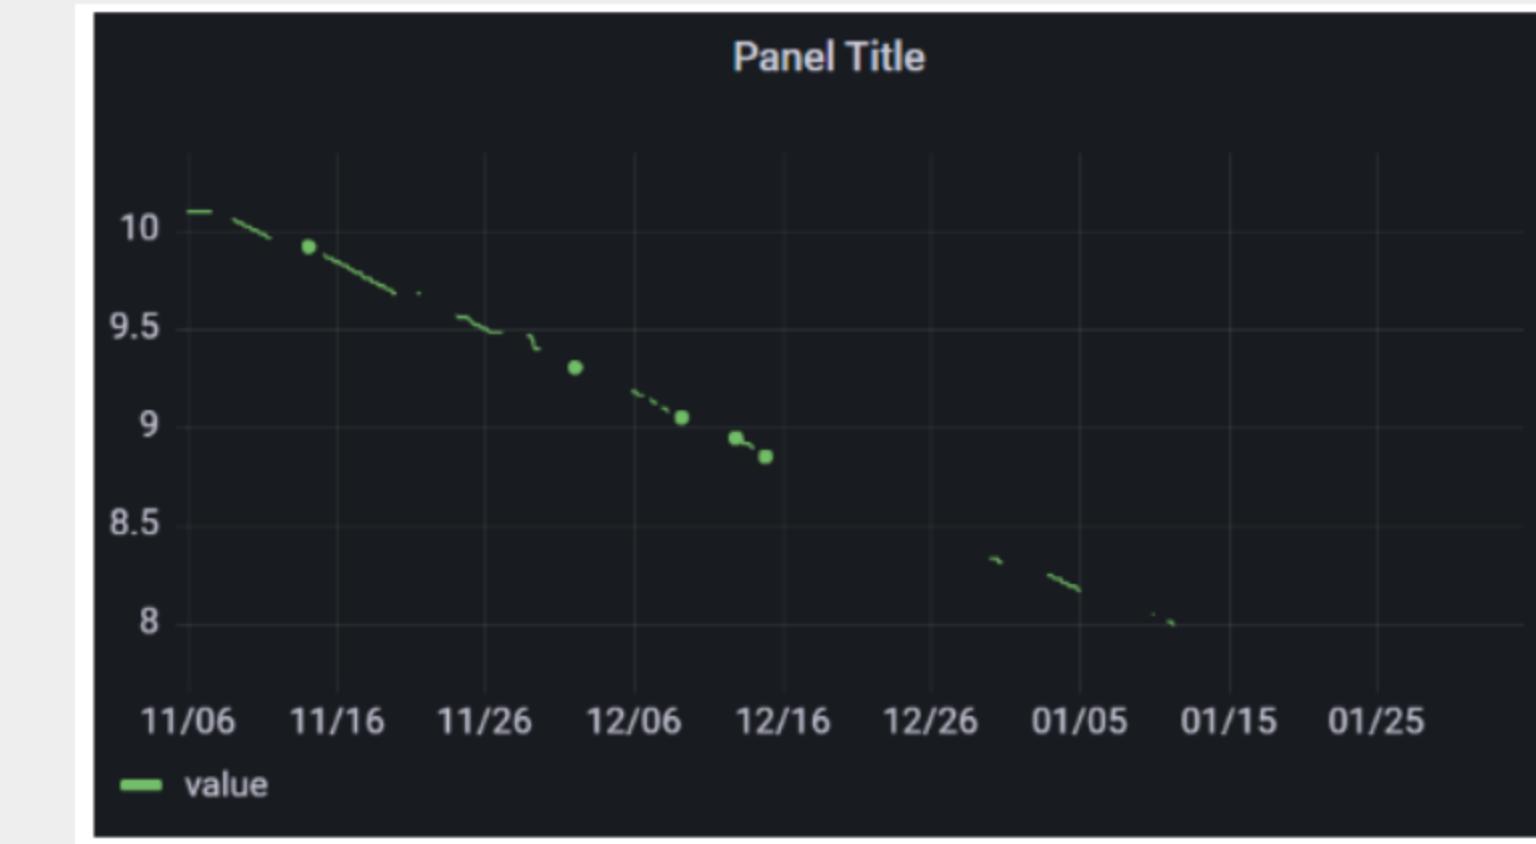


# 이상치 및 결측치 처리

**GW\_WHEEL\_REMAIN**



**RW\_WHEEL\_REMAIN**

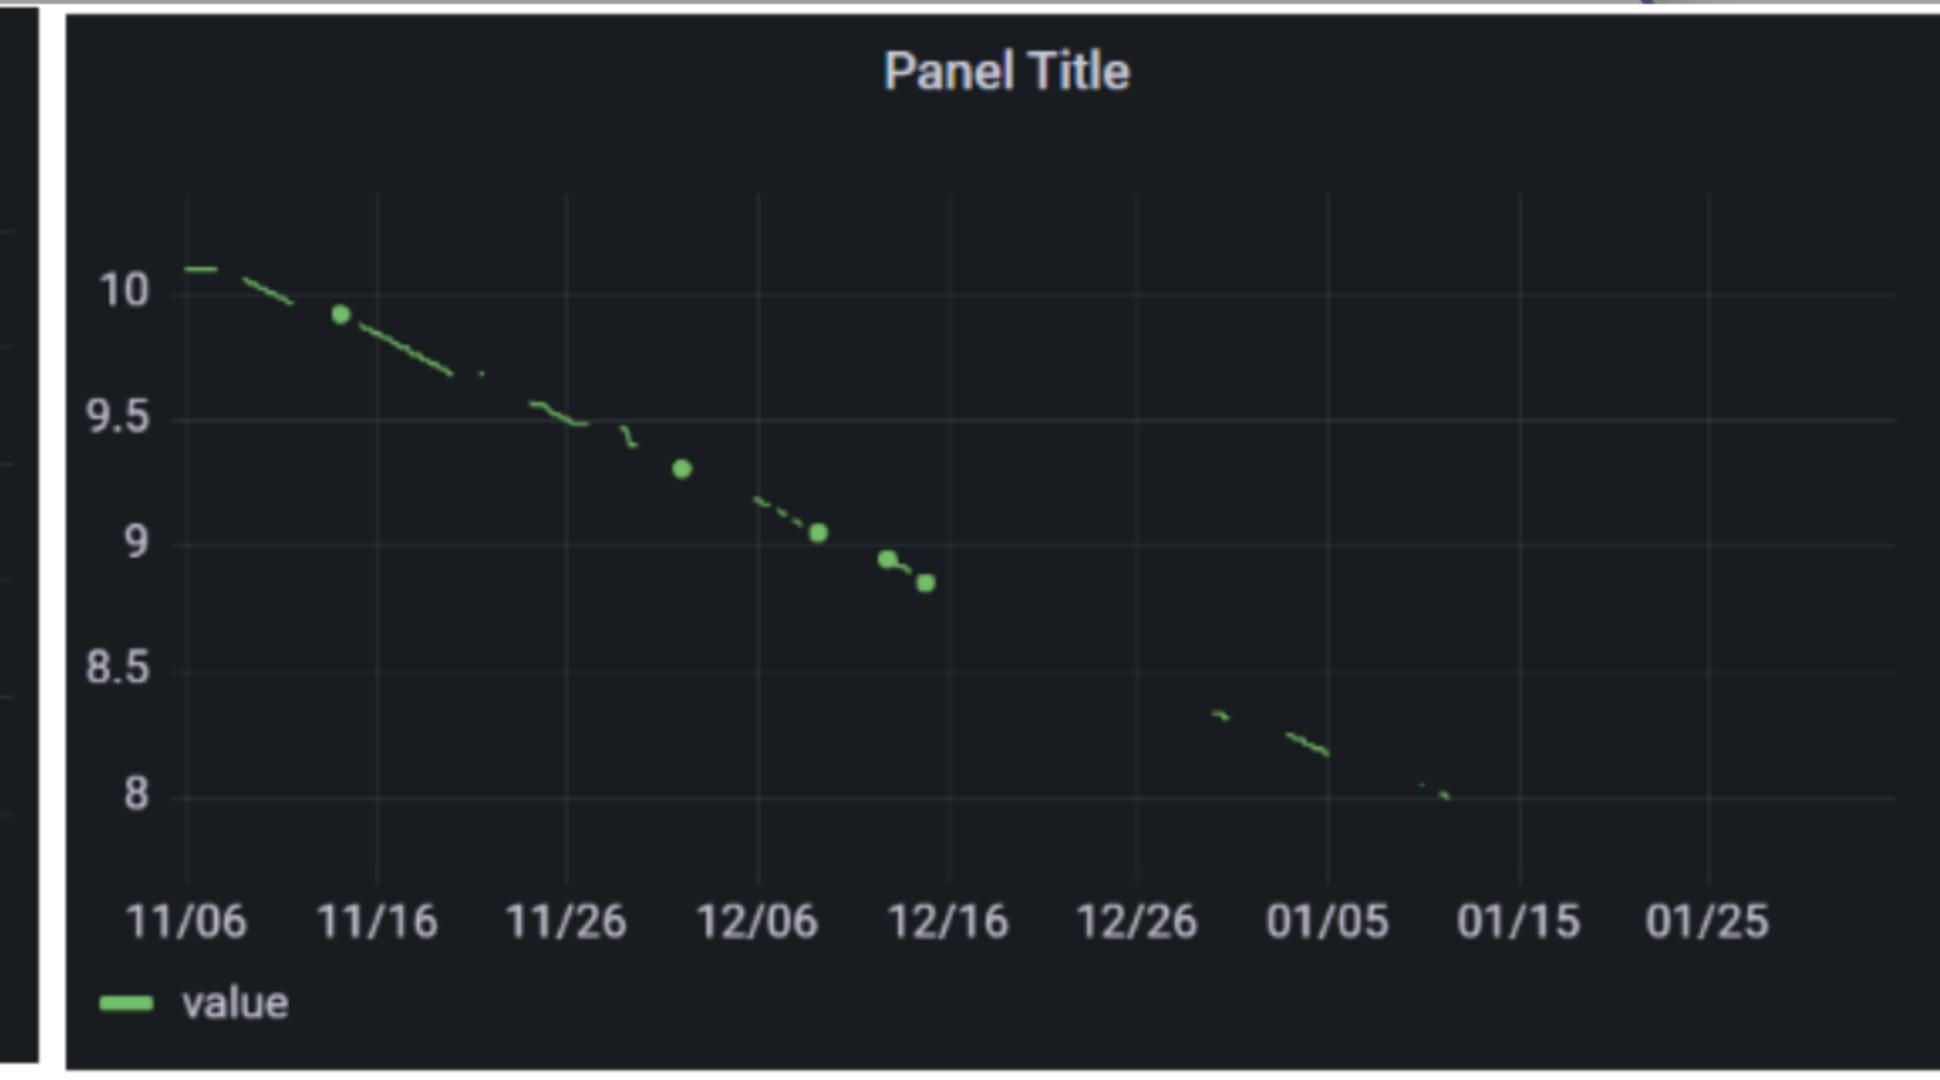


# 이상치 및 결측치 처리

Panel Title



Panel Title



## 이상치 처리

- ✓ 7일보다 짧은 주기로 훨 잔량의 감소율을 계산하니  
예상 교체 날짜가 크게 변경되어서 감소율을 계산하는 기간을 7일로 결정
- ✓ 감소율이 평균보다 크게 나타나는 부분은 이상치로 판단 후 이전 값으로 대체

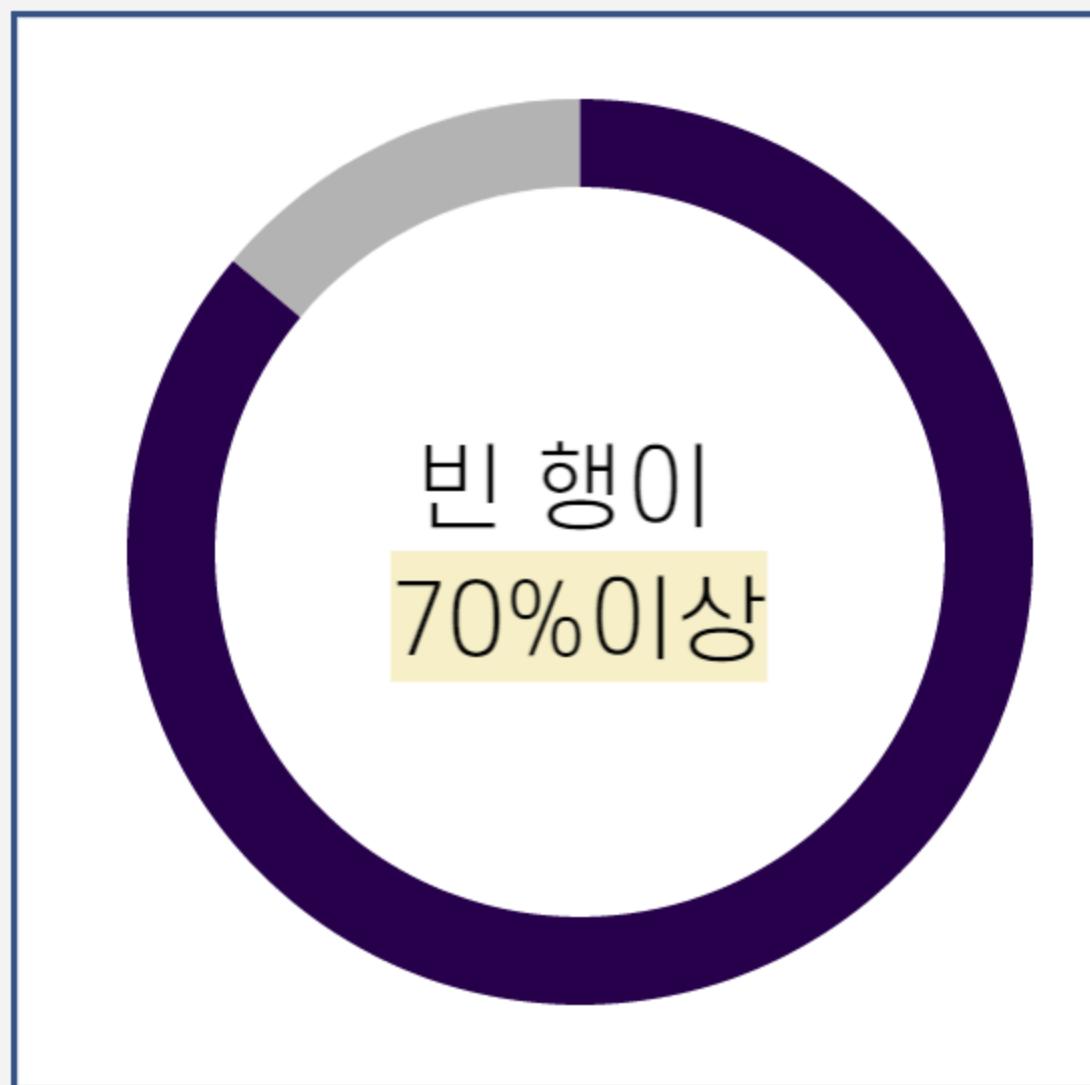


# 결측치 처리

- ✓ 'time' 열에 결측치 존재함.
- ✓ 통신 장애로 인해 데이터가 수집되지 않은 날이 많았음.
- ✓ date\_range를 통해 'time' 열의 결측값을 채워줌.
- ✓ 'time' 열의 새로운 행이 생기면서 다른 열의 결측치가 새로 생기게 됨.
- ✓ 교체된 날이 기록되지 않아서 이전, 이후 값을 토대로 전체 기울기를 계산하여 교체 지점을 예측하여 지정
- ✓ 'RW\_WHEEL\_REMAIN' 과 'GW\_WHEEL\_REMAIN' 열의 결측치를 선형 보간법을 통해 보간

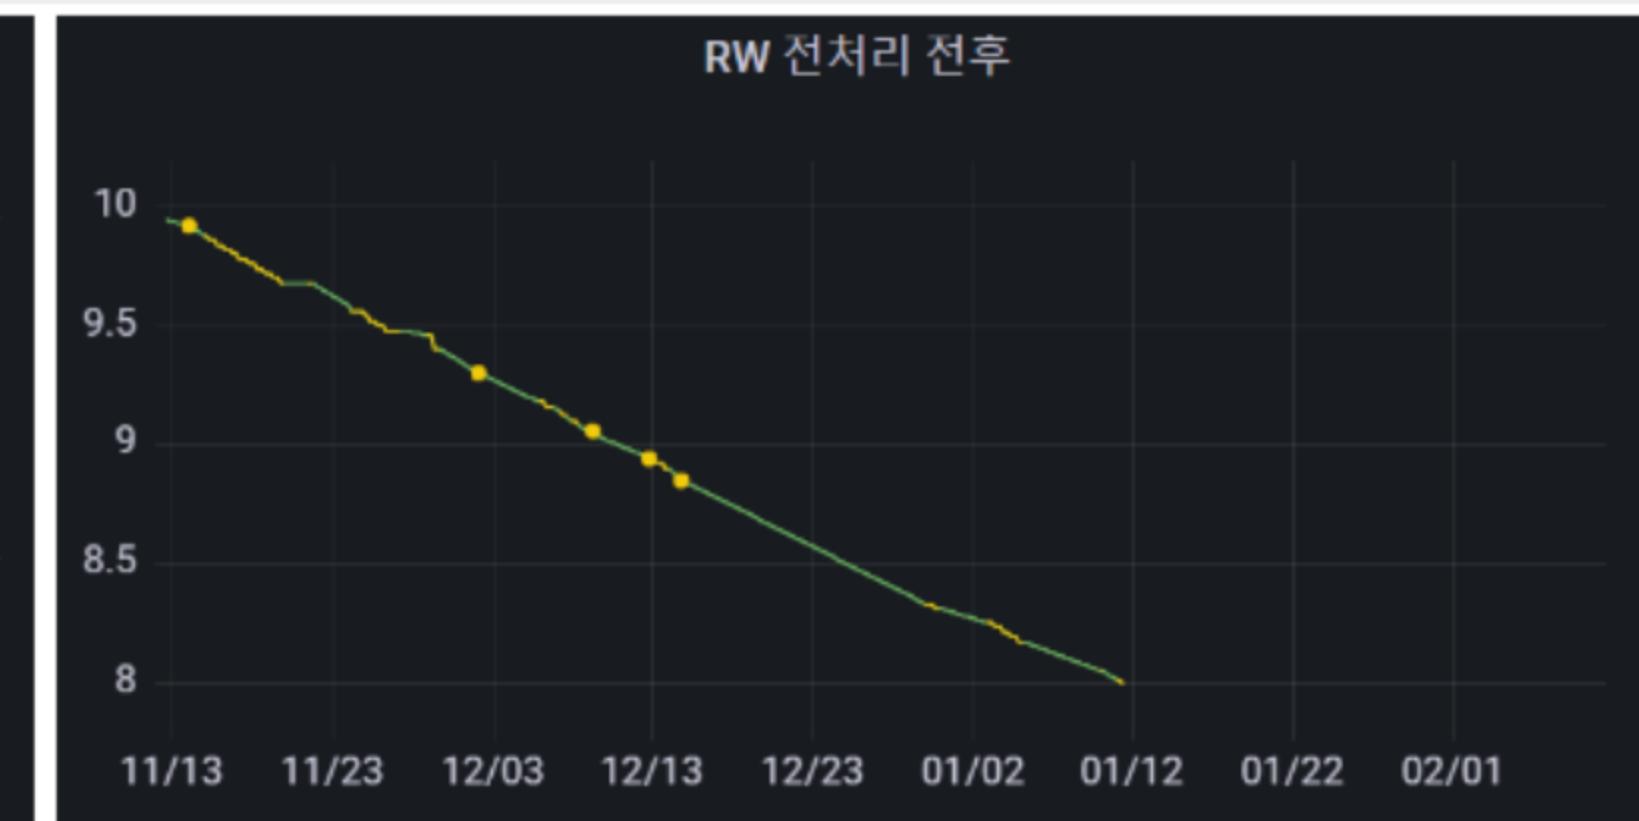


# 시계열 자료 기울기 문제 해결과정 (1)



$$\frac{y_2 - y_1}{x_2 - x_1} = \text{기울기}$$
$$\frac{8.44 - 39.62}{40} = -0.78$$

# 계산을 통해 보간한 그래프



- 노란 그래프 : 전처리 전
- 녹색 그래프 : 전처리 후

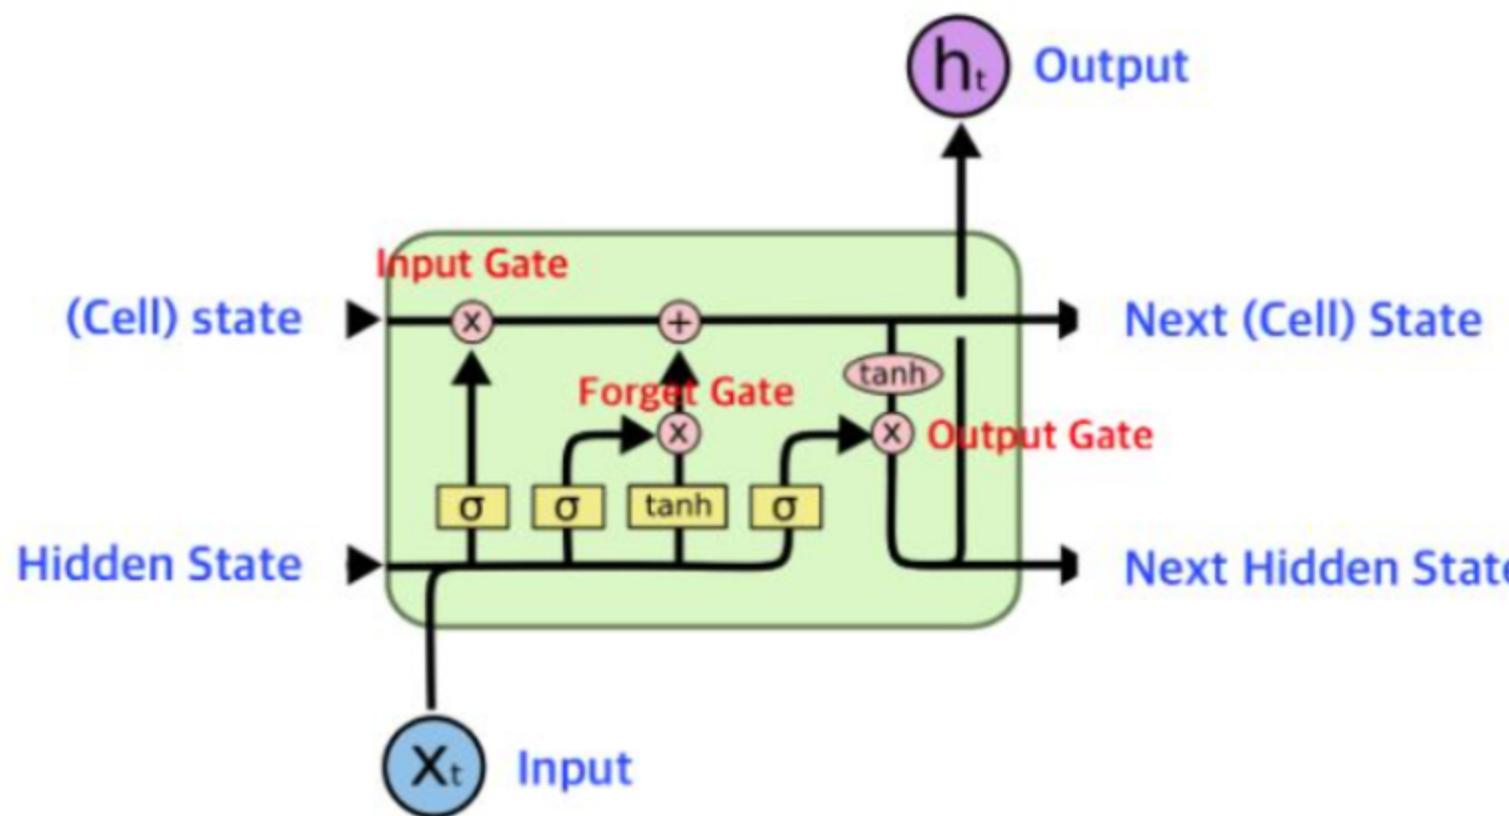
# 계산을 통해 보간한 그래프



- 노란 그래프 : 전처리 전
- 녹색 그래프 : 전처리 후

# 사용 알고리즘

## LSTM



순환 신경망 기법 중 하나로 셀, 입력 게이트,  
출력 게이트, 망각 게이트를 이용해  
기존 순환 신경망의 문제점을 방지한 알고리즘

## ARIMA

$ARIMA(p, d, q)$

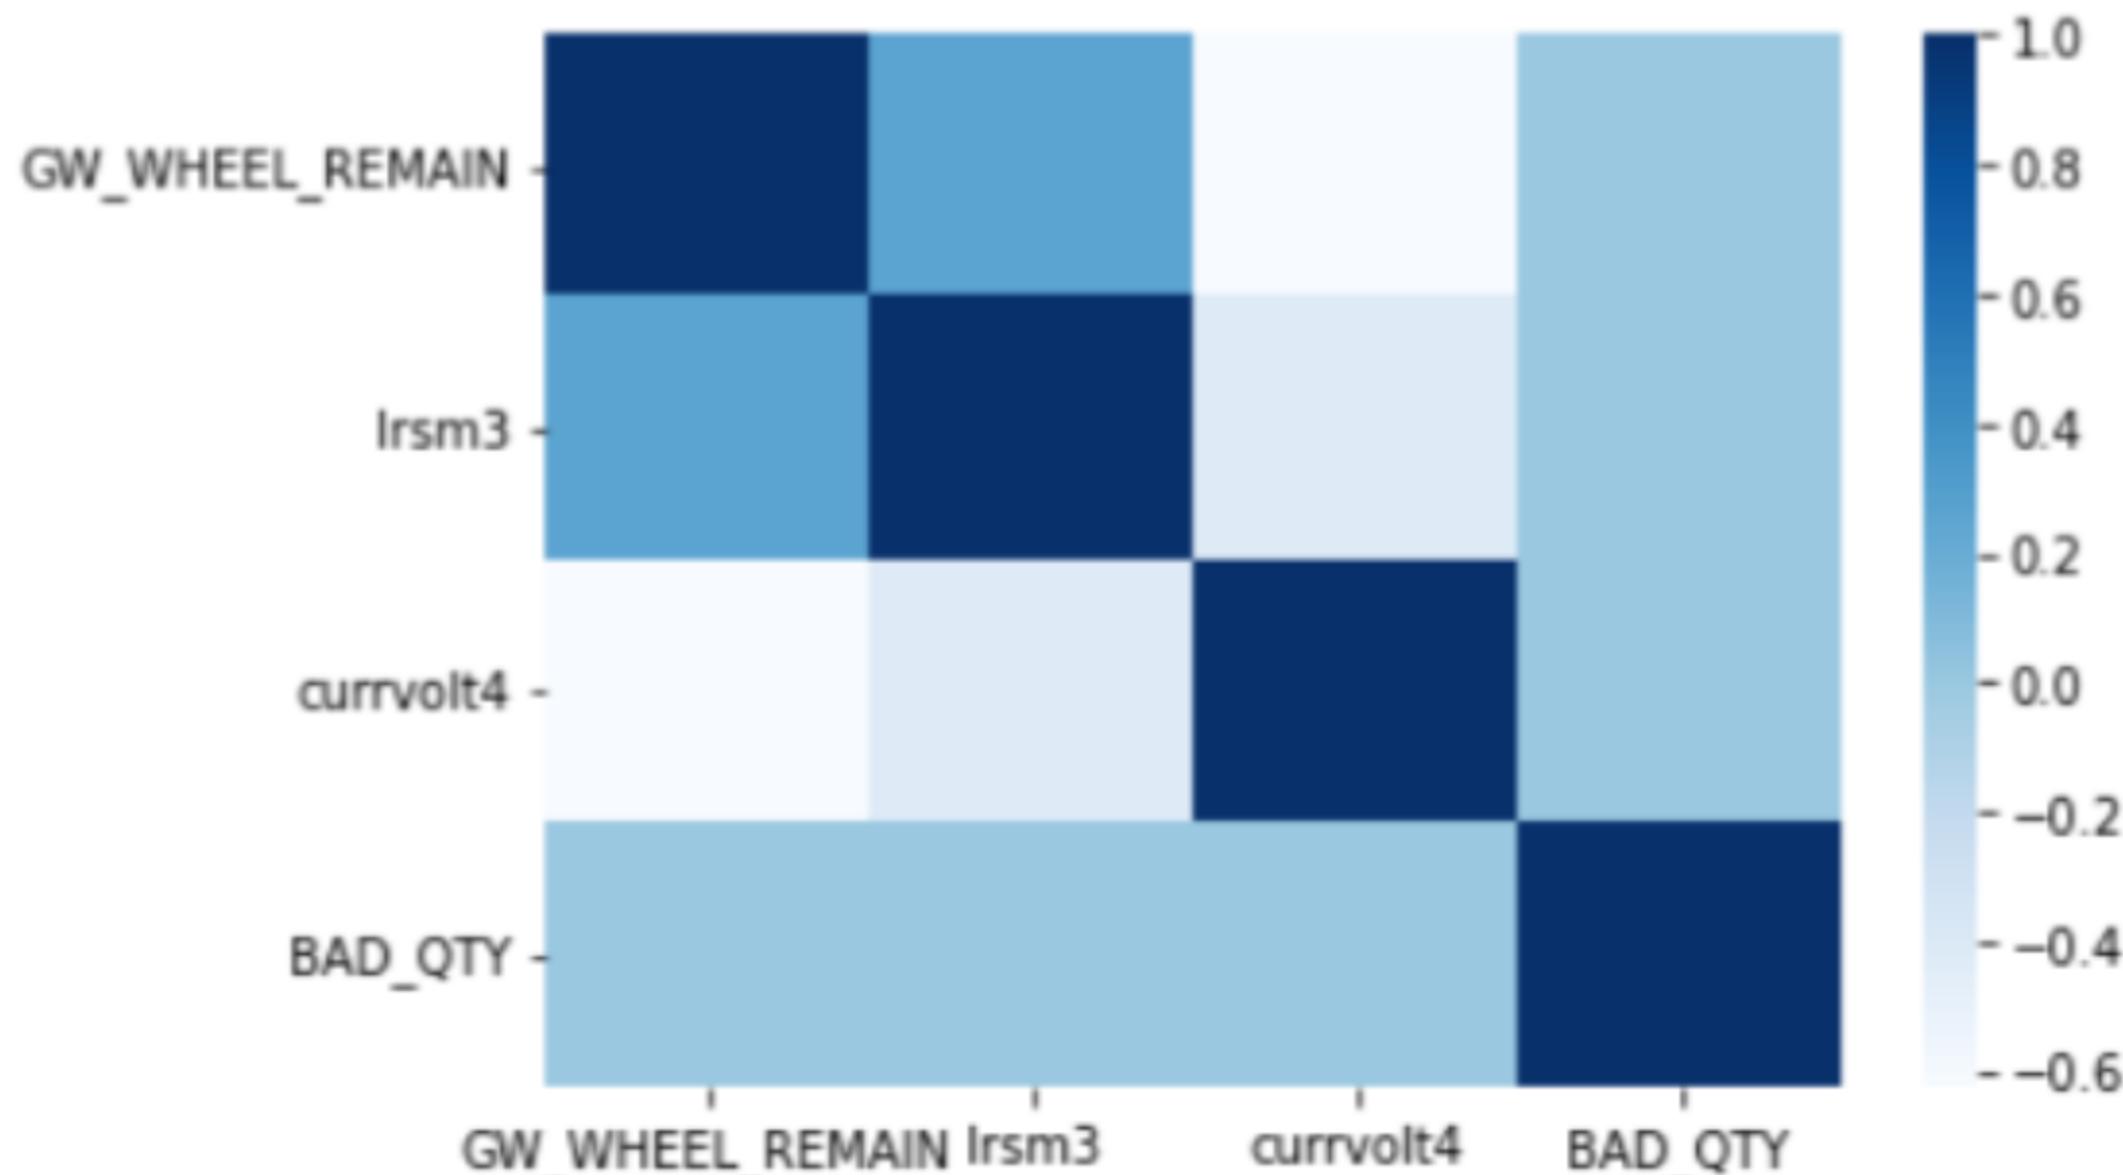


ARIMA는 차분, 변환을 통해  
AR, MA, ARMA로 정상화

- $p=0$ 이면 IMA( $d, q$ )  $\rightarrow$   $d$ 번 차분하면 MA( $q$ )
- $d=0$ 이면 ARMA( $p, q$ )  $\rightarrow$  정상성 만족
- $q=0$ 이면 ARI( $p, d$ )  $\rightarrow$   $d$ 번 차분하면 AR( $p$ )

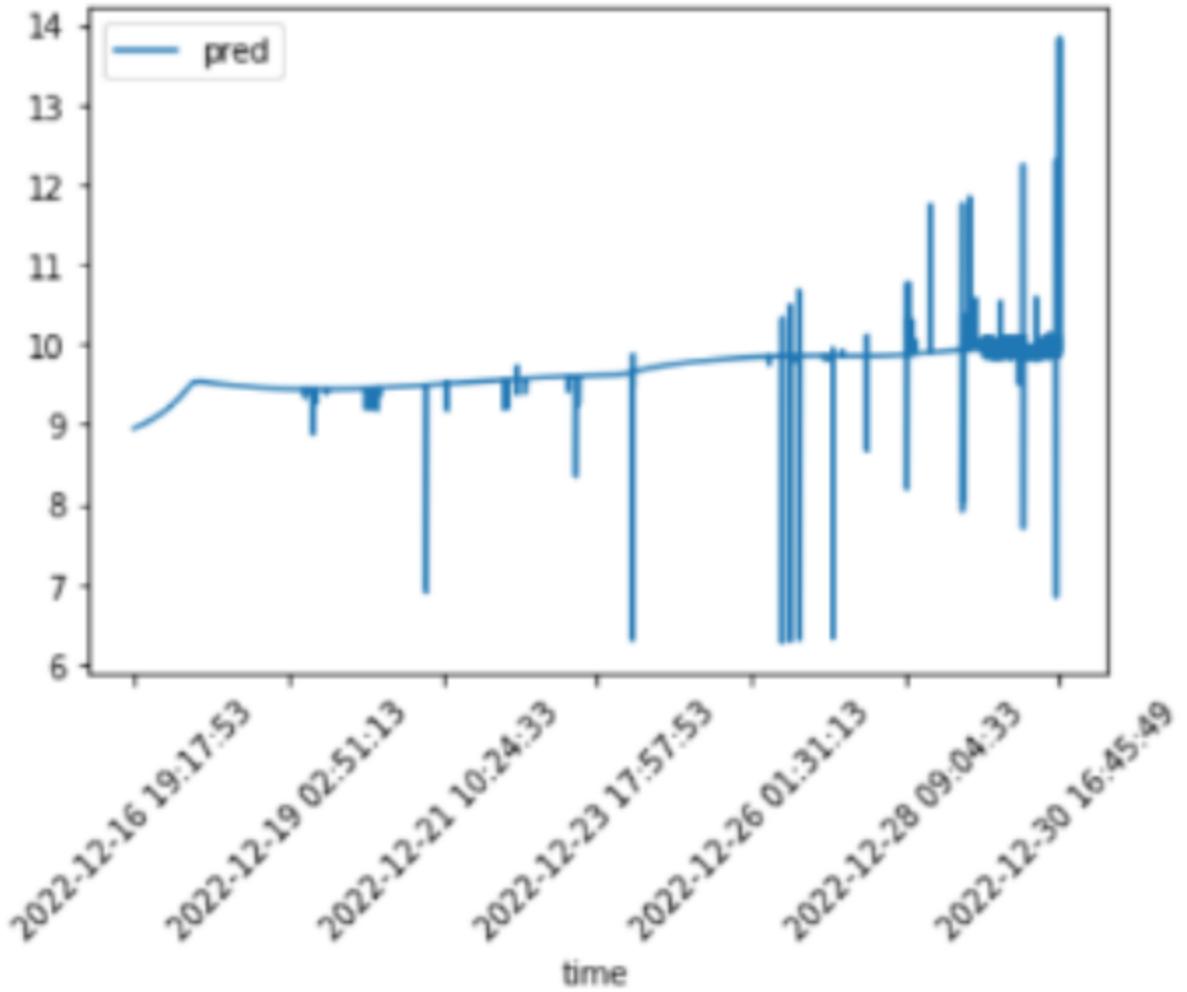
자기회귀와 이동평균을 모두 고려하여  
시계열 데이터 기반 분석 기법으로  
현재 값을 과거 값과 과거 예측값의 오차를  
통해 설명하며 예측하는 알고리즘

# 데이터 전처리 Feature 탐색

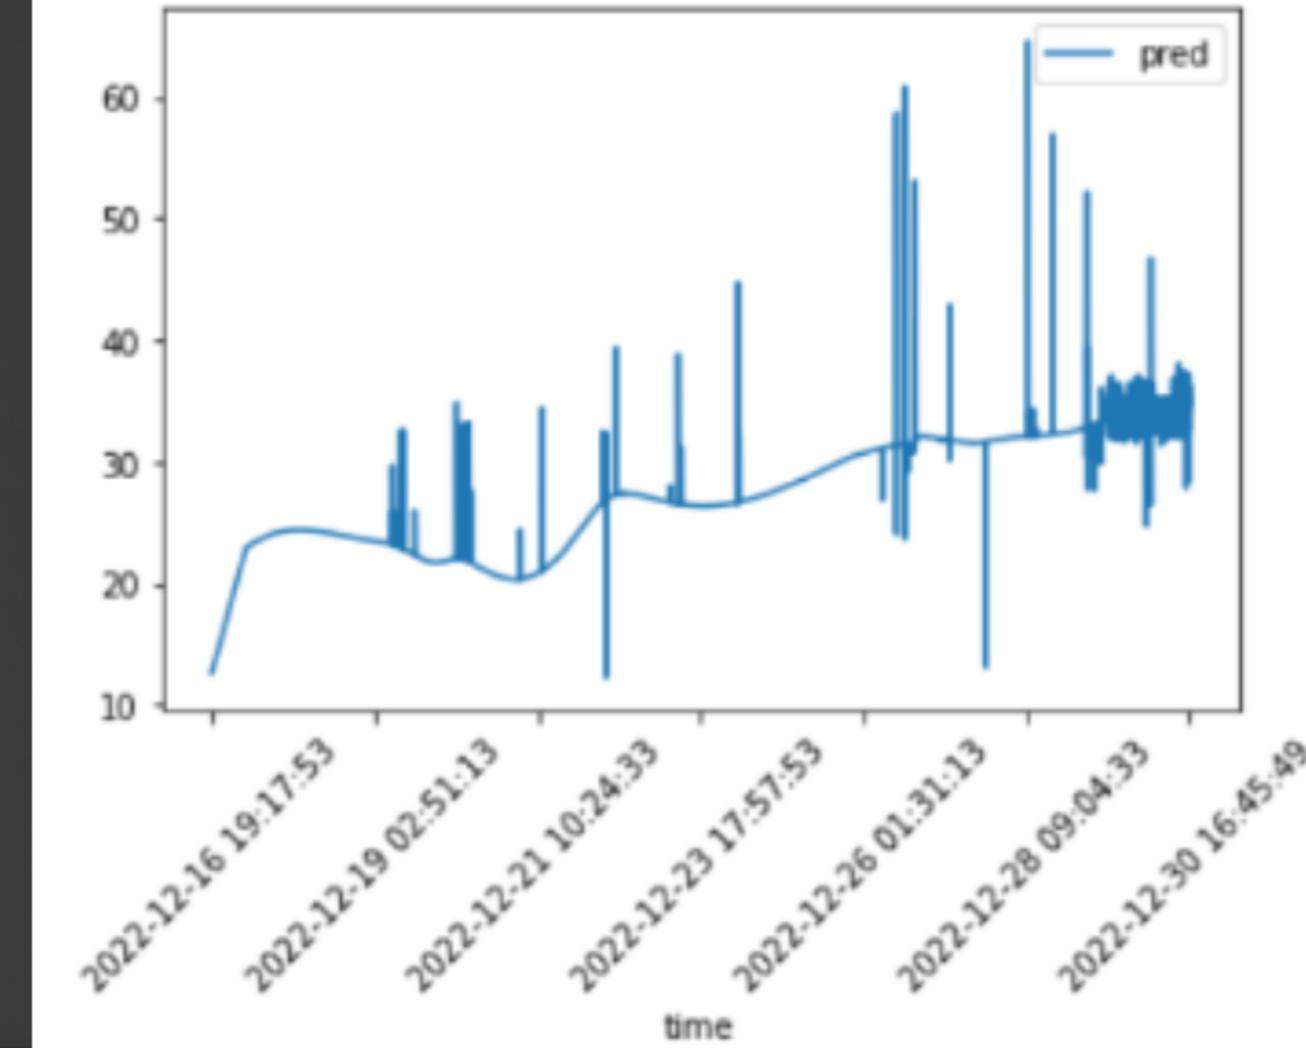


예측해야 할 열인  
GW\_WHEEL\_REMAIN과  
RW\_WHEEL\_REMAIN과  
상관관계를 보이는 열이  
없음을 알 수 있다.

# LSTM



RW\_WHEEL\_REMAIN 예측 그래프



GW\_WHEEL\_REMAIN 예측 그래프

LSTM을 사용하고자 하였으나 독립변수들간의 상관성이 낮았기 때문에 예측이 제대로 되지 않음

# ARIMA

```
Performing stepwise search to minimize aic  
ARIMA(2,1,2)(0,0,0)[0] intercept : AIC=-10250185.215, Time=212.11 sec  
ARIMA(0,1,0)(0,0,0)[0] intercept : AIC=-10223672.280, Time=82.45 sec  
ARIMA(1,1,0)(0,0,0)[0] intercept : AIC=-10245366.942, Time=104.53 sec  
ARIMA(0,1,1)(0,0,0)[0] intercept : AIC=-10241692.866, Time=324.58 sec  
ARIMA(0,1,0)(0,0,0)[0] : AIC=-10223143.811, Time=25.26 sec  
ARIMA(1,1,2)(0,0,0)[0] intercept : AIC=-10250114.441, Time=190.16 sec  
ARIMA(2,1,1)(0,0,0)[0] intercept : AIC=-10250054.021, Time=176.38 sec  
ARIMA(3,1,2)(0,0,0)[0] intercept : AIC=-10250204.681, Time=237.42 sec  
ARIMA(3,1,1)(0,0,0)[0] intercept : AIC=-10250110.039, Time=181.26 sec  
ARIMA(4,1,2)(0,0,0)[0] intercept : AIC=-10250193.457, Time=302.96 sec  
ARIMA(3,1,3)(0,0,0)[0] intercept : AIC=-10250202.716, Time=301.47 sec  
ARIMA(2,1,3)(0,0,0)[0] intercept : AIC=-10250204.575, Time=273.29 sec  
ARIMA(4,1,1)(0,0,0)[0] intercept : AIC=-10250173.053, Time=266.81 sec  
ARIMA(4,1,3)(0,0,0)[0] intercept : AIC=-10250200.567, Time=332.71 sec  
ARIMA(3,1,2)(0,0,0)[0] : AIC=-10250078.442, Time=314.53 sec  
  
Best model: ARIMA(3,1,2)(0,0,0)[0] intercept  
Total fit time: 3325.943 seconds
```

ARIMA의 차수 p,d,q 값을 얻기 위해  
auto arima를 실행해서 best model을 구했다.

최적 모델인 ARIMA(3,1,2)를 이용해서  
모델링을 진행했다.

정확도를 높이기 위해  
처음 7일을 이용해 모델을 fit 한 후,  
다음 1일을 forecast하는 방식을 이용했다.

# ARIMA



## 모형평가

구분	RW 월	GW 월
MAE	0.012	0.297
RMSE	0.0177	0.4060
MAPE	0.129	3.792
R <sup>2</sup>	0.999	0.998

제공받은 RW월 잔량 데이터에 교체된 구간에 대한  
데이터가 누락되었기에 그 부분에 대한 데이터가 보완된다면  
조금 더 나은 결과를 도출할 수 있을 것으로 기대된다.

# 무엇이 문제인가?

데이터  
부족

모델 사용  
불가능

상관성  
부족

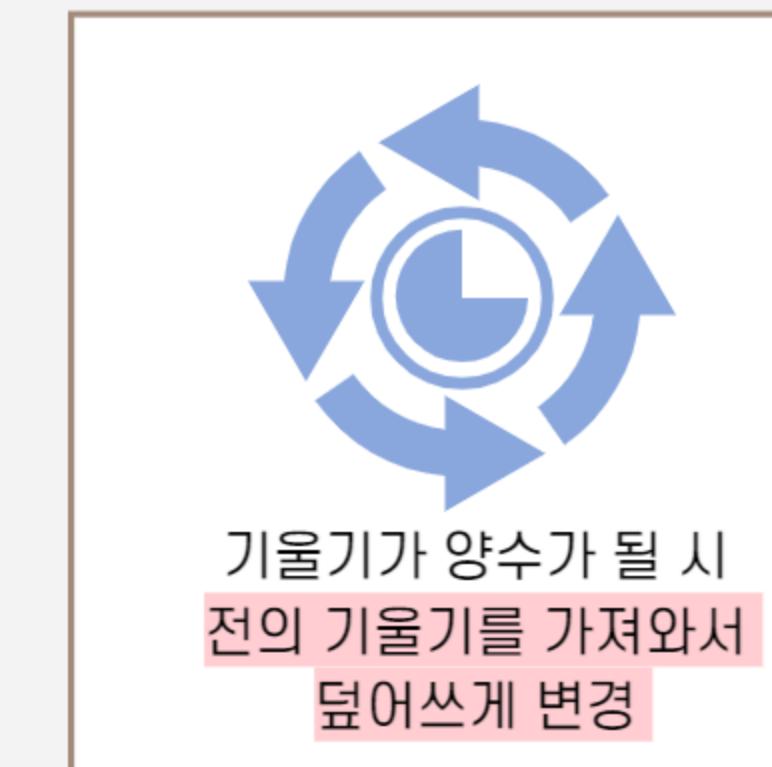
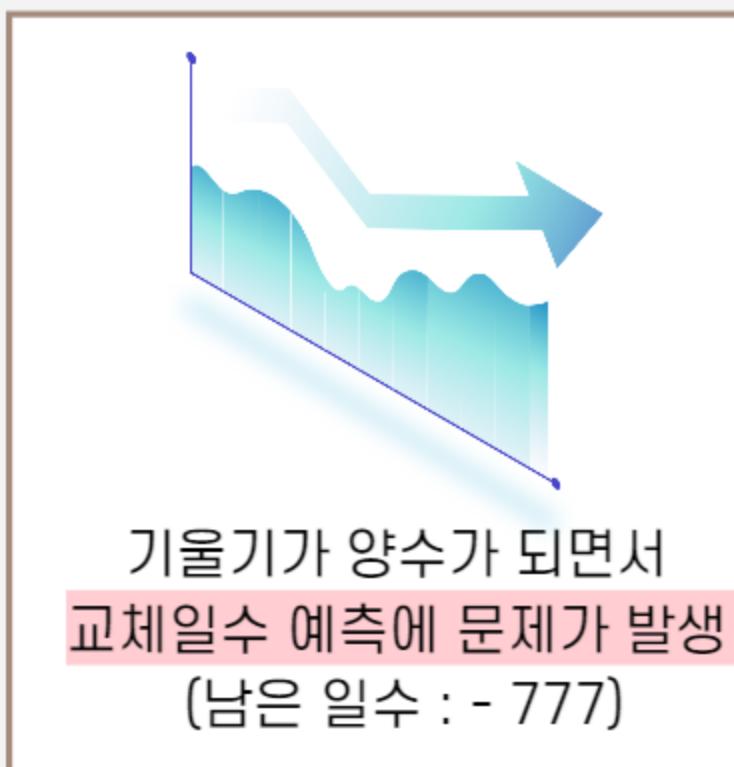
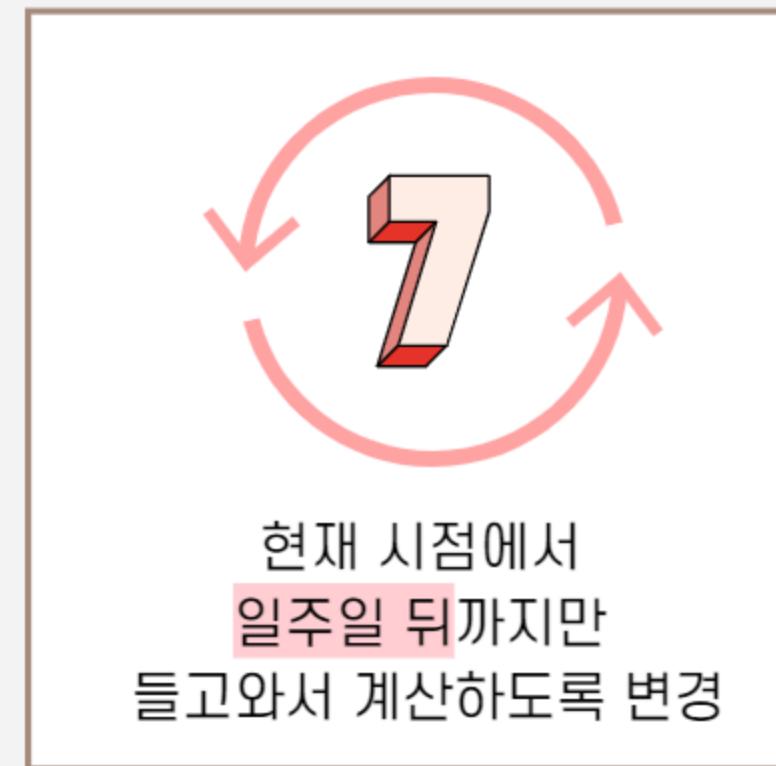
기울기  
계산

보간법



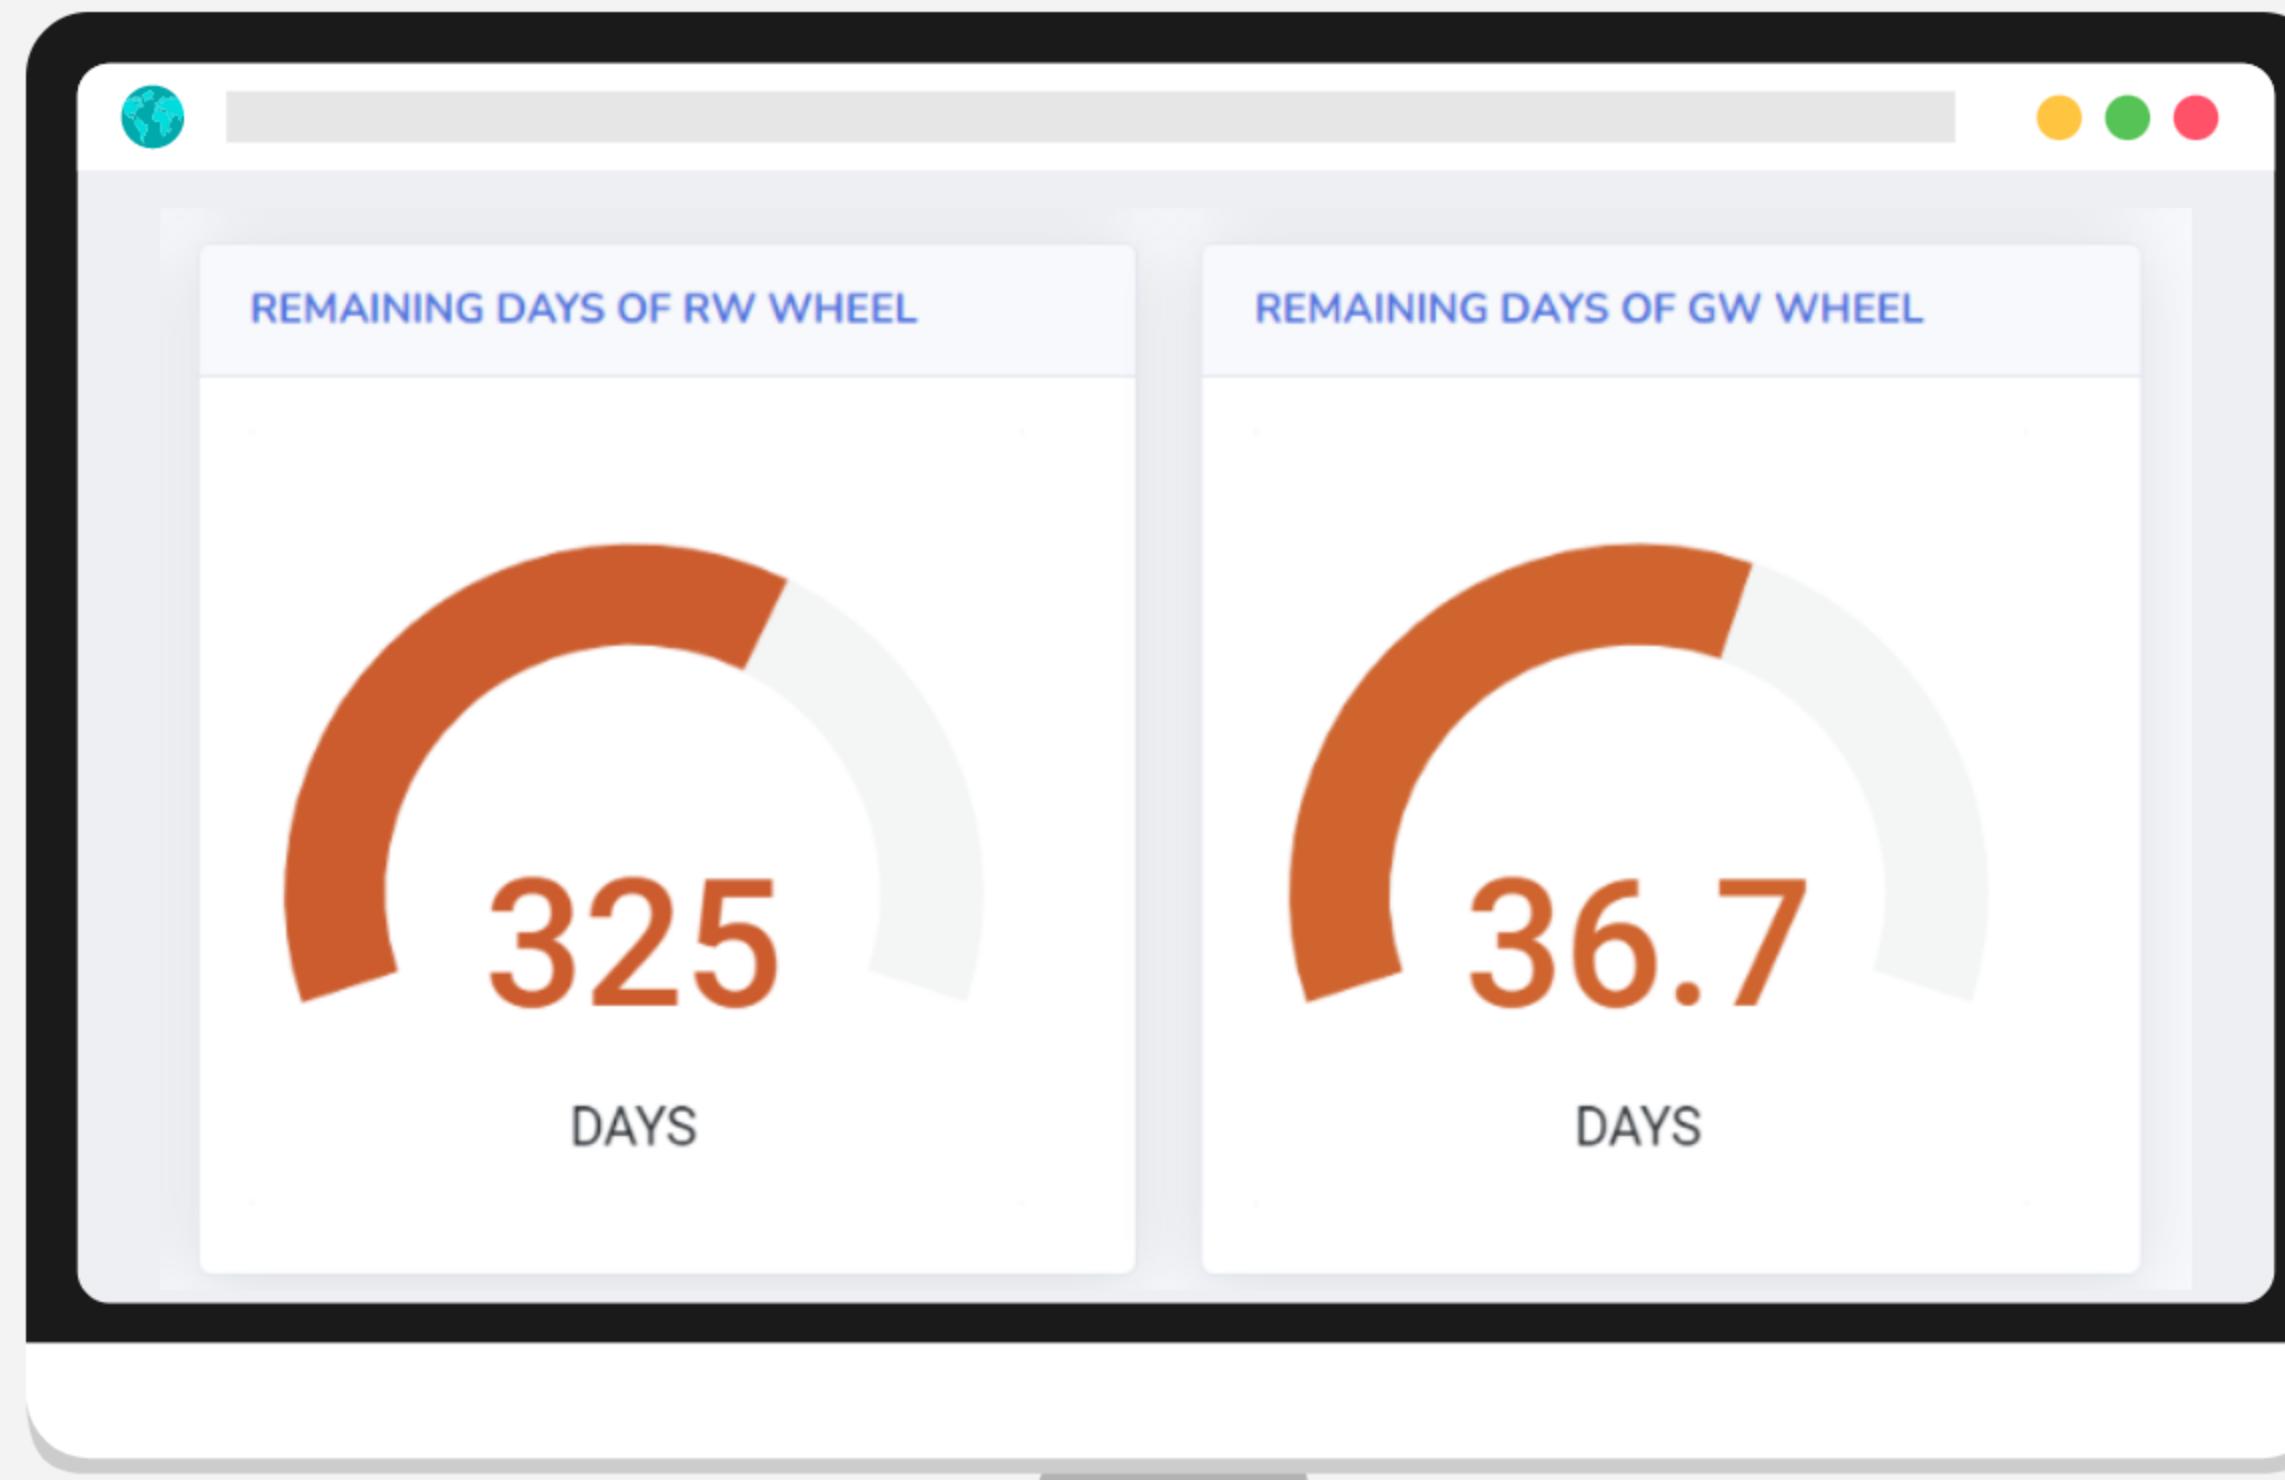
(실제 생각)

# 시계열 자료 기울기 문제 해결과정 (2)



# 시계열 예측 데이터 활용안

: GW/RW 훈련량 및 교체시기 예측



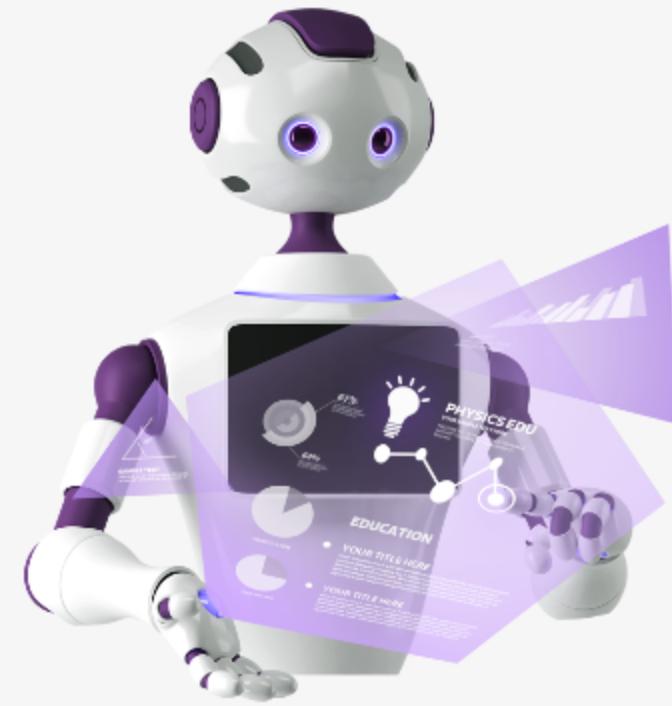


# 05

## 기대효과

# 프로젝트 기대효과

## 정량적 효과



- AI 데이터 분석을 통해 기존의 훨 교체주기 대비  
생산량이 10% 이상 상승할 것으로 기대

- 훨 잔량 및 교체 주기를 예측하는  
AI 분석 모델을 이용하여  
이상감지 정확도가 80% 이상 될 것으로 기대

## 정성적 기대효과



- 설비 상태 및 훨 잔량 데이터를 분석하여  
설비 예지보전 시스템 구축

- 실시간 모니터링 시스템을 통해  
제조 라인에서 작업자들이  
실시간 대응이 가능하도록 구현



# 06

## 프로젝트 소감

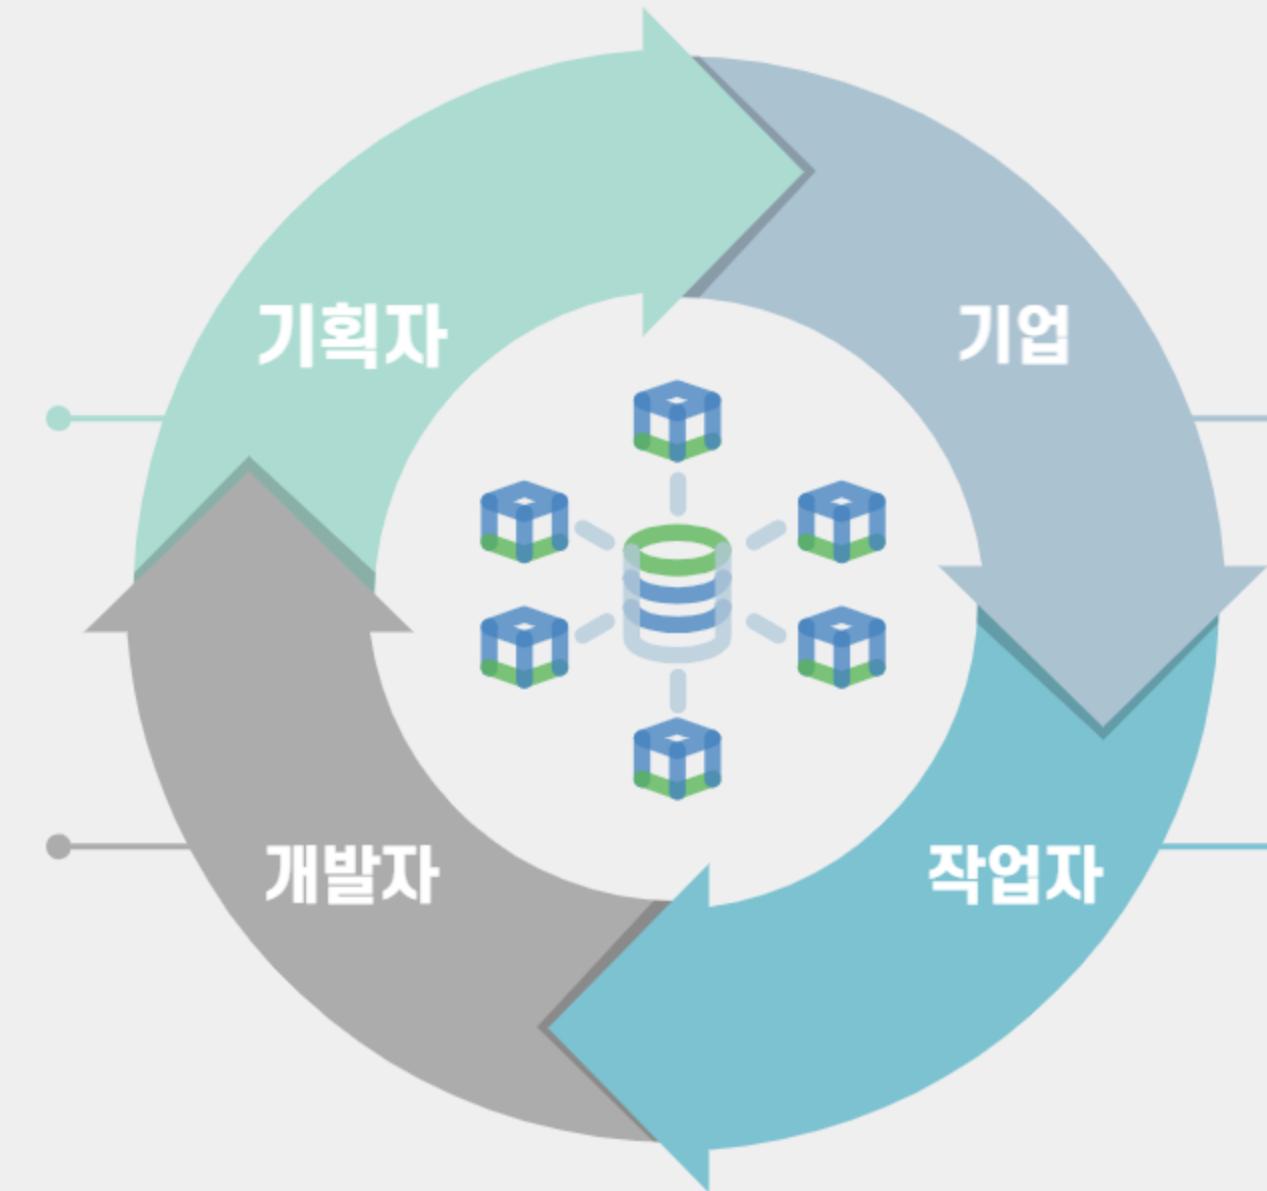
# 한계점 및 개선점

데이터의 대부분이 훨씬 두께와 상관없는 열밖에 없었다.  
따라서 연관성이 있는 데이터가 있었다면  
다양한 알고리즘을 사용해서 더 좋은 결과가 나왔을 것.

기업 특성상 실시간 데이터를 제공해 줄 수 없다고 해서  
이전 시점의 데이터만 사용해서 예측을 하였다.  
하지만 데이터를 실시간으로 받을 수 있다면  
DB에 실시간으로 저장하고 바로 전처리 후 모델에까지 적용 할 수 있을 것.



스마트 팩토리를  
이상적으로 구축하려는 기획자



열약한 데이터를 통해  
시스템을 만들어야하는 개발자

보안상의 이유로  
한정된 데이터만 전달하는 기업

실제 현장에서 일하는 작업자

이 모두가 능동적으로 서로의 간격을 좁히는게  
**스마트팩토리의 악순환**을 푸는 열쇠

---

# Q & A

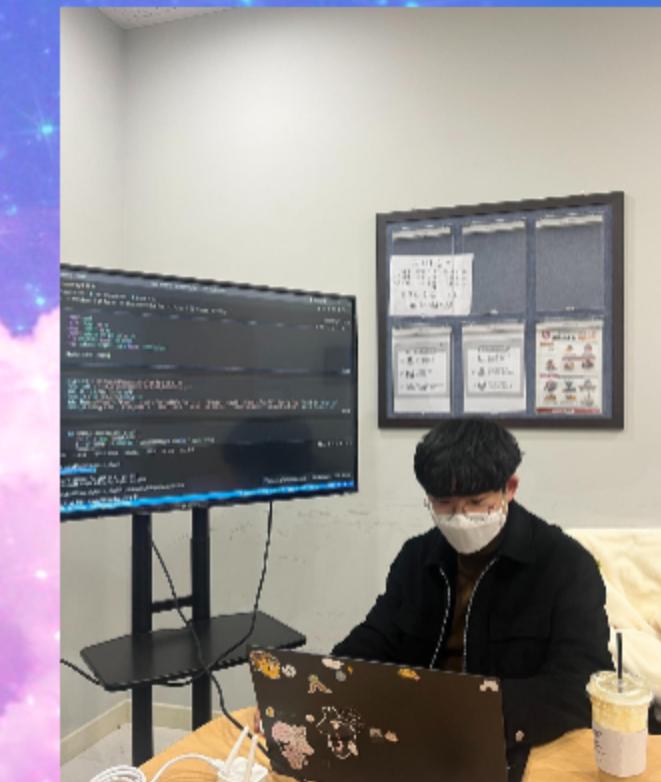
# Up Town Together!

최정인 :

분석한 데이터를 효율적으로 고객사에게 보여줄 수 있는 방법에 대해 고민하였고, 이를 통해서 다양한 서비스 또한 기획할 수 있는 시간을 얻었다.

최창규 :

실무데이터가 기대한것보다 훨씬 복잡해서 사용하는데 애먹었지만 그 덕분에 많이 배웠다.



강보원 :

시계열 데이터의 전처리, 모델링에 대해 많이 학습할 수 있는 기회가 되었다고 생각한다. 다음에는 더 다양한 모델과 다양한 데이터를 이용한 시계열 분석에 도전해보고 싶다.

박현명 :

앞으로 마주하게 될 살벌할 데이터들을 미리 체험할 수 있어서 이번 프로젝트는 의미가 깊었다. 마음의 준비를 하고, 현장 데이터를 잘 다룰 수 있는 분석가가 되어야겠다.